

Dự án Học máy — Dự đoán thời điểm tái đặt hàng của nhà thuốc (PharmaDist)

Họ và tên: Hoàng Phi Hải | Mã số sinh viên: 25MS23323

1. Bối cảnh và mục tiêu

PharmaDist là một nhà phân phối dược phẩm B2B, cung cấp thuốc và thực phẩm chức năng cho mạng lưới nhà thuốc trên cả ba miền. Doanh nghiệp mong muốn dự đoán **thời điểm mỗi nhà thuốc phát sinh đơn hàng tiếp theo**, nhằm giúp đội ngũ trình dược viên chủ động chăm sóc khách hàng trước khi họ ngừng giao dịch và chuyển sang nhà phân phối khác.

Từ 7 tập dữ liệu thô, dự án xây dựng một quy trình hoàn chỉnh: khám phá, làm sạch, tích hợp, tạo đặc trưng, xây dựng nhãn mục tiêu, huấn luyện — đánh giá mô hình và đưa ra khuyến nghị.

Biến mục tiêu (thực hiện cả hai bài toán):

- `days_until_next_order` — số ngày đến đơn hàng kế tiếp (bài toán **hồi quy**).
- `will_reorder_within_45_days` — khả năng tái đặt hàng trong 45 ngày (bài toán **phân loại**).

2. Quy trình thực hiện

Bước	Nội dung
0	Xác định bài toán và ràng buộc của đề bài
1	Phân tích khám phá dữ liệu (EDA) — nội dung của notebook này
2	Làm sạch dữ liệu (giá trị thiếu, ngoại lai, định dạng ngày, ràng buộc logic)
2.5	Tích hợp 7 bảng và tính <code>total_amount</code>
3	Biến đổi dữ liệu (chuẩn hóa, mã hóa)
4	Xây dựng đặc trưng (RFM và các nhóm hành vi)
4.5	Xây dựng nhãn mục tiêu và xử lý hiện tượng censoring
5	Phân chia dữ liệu theo thời gian (chống rò rỉ)
6	Huấn luyện (hồi quy tuyến tính / logistic) và đánh giá
7	Báo cáo và khuyến nghị

Nguyên tắc xuyên suốt — chống rò rỉ dữ liệu (data leakage): mọi tham số ước lượng từ dữ liệu (giá trị điền khuyết, trung bình/độ lệch chuẩn để chuẩn hóa, danh mục để mã hóa) chỉ được học trên **tập huấn luyện** rồi áp dụng cho tập kiểm tra. Riêng bước EDA chỉ **quan sát**, chưa thực hiện biến đổi dữ liệu.

3. Bước 0 — Xác định ràng buộc của đề bài

Trước khi khảo sát dữ liệu, cần xác định các ràng buộc bắt buộc nêu trong đề bài. Mỗi ràng buộc vừa quy định phương pháp được phép sử dụng, vừa định hướng nội dung cần tập trung khảo sát trong phần EDA.

Ràng buộc của đề bài	Hệ quả về phương pháp	Nội dung EDA cần khảo sát
Chỉ dùng hồi quy tuyến tính / logistic (không dùng cây quyết định, XGBoost, SHAP)	Độ quan trọng đặc trưng được đo bằng độ lớn standardized coefficient	Multicollinearity (corr/VIF) và quan hệ phi tuyến
Phân chia dữ liệu theo thời gian	Không dùng phân chia ngẫu nhiên	Drift giữa giai đoạn cũ và mới; mốc thời gian cắt
Nhãn mục tiêu phải tự xây dựng	Suy ra nhãn từ mốc thời gian	Độ phủ đơn hàng và hiện tượng censoring
Dữ liệu gồm 7 bảng	Phải tích hợp, phân biệt LEFT/INNER JOIN	Toàn bộ quan hệ khóa giữa các bảng
Lớp mục tiêu mất cân bằng	Dùng F1 / PR-AUC thay cho Accuracy	Kiểm tra mức độ cân bằng lớp

Cần phân biệt hai loại ràng buộc: **(i) ràng buộc từ đề bài** — biết trước khi tiếp cận dữ liệu; **(ii) ràng buộc do dữ liệu bộc lộ** (mất cân bằng lớp, multicollinearity, cửa sổ rò rỉ thời gian, số lượng bản ghi bị censoring) — chỉ phát hiện được qua EDA. Loại (i) định hướng cho EDA nhằm phát hiện loại (ii) đúng trọng tâm.

4. Bước 1 — Phân tích khám phá dữ liệu (EDA)

Phân phân tích được tổ chức thành ba phần:

- Phần A** — khảo sát từng bảng dữ liệu (tổng quan, phân phối, giá trị thiếu, ngoại lai, ràng buộc miền giá trị).
- Phần B** — khảo sát quan hệ giữa các bảng (tính toàn vẹn khóa, hiện tượng censoring).
- Phần C** — khảo sát theo định hướng mô hình (multicollinearity, drift theo thời gian).

Kết quả của bước này là **bảng tổng hợp các vấn đề dữ liệu**, làm đầu vào cho bước làm sạch.

4.1. Thiết lập môi trường và nạp dữ liệu

```
In [1]: import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
import missingno as msno
import warnings, re
warnings.filterwarnings('ignore')

sns.set_theme(style='whitegrid')
plt.rcParams['figure.figsize'] = (9, 4)
plt.rcParams['axes.unicode_minus'] = False
pd.set_option('display.max_columns', 50)
pd.set_option('display.width', 200)

DATA_DIR = '../HW/'
FILES = ['pharmacies', 'orders', 'order_lines', 'products',
        'support_tickets', 'sales_engagements', 'warehouses']
data = {f: pd.read_csv(DATA_DIR + f + '.csv') for f in FILES}

REF_DATE = pd.Timestamp.now().normalize() # mốc thời gian tham chiếu (động, không cố định năm)

def make_grid(n, ncol=3, h=3.5):
    '''Tạo lưới subplot tự động đủ ô cho n biểu đồ (số hàng tính theo n),
    bảo đảm không bỏ sót đối tượng nào khi vẽ theo vòng lặp.'''
    nrow = int(np.ceil(n / ncol))
    fig, axes = plt.subplots(nrow, ncol, figsize=(16, h * nrow))
    return fig, np.atleast_1d(axes).ravel()

print('Đã nạp', len(data), 'bảng dữ liệu. Mốc tham chiếu:', REF_DATE.date())
for f in FILES:
    print(f' {f:20s} {data[f].shape}')
```

Đã nạp 7 bảng dữ liệu. Mốc tham chiếu: 2026-06-28

pharmacies	(800, 8)
orders	(3500, 8)
order_lines	(7740, 4)
products	(150, 7)
support_tickets	(700, 7)
sales_engagements	(1800, 8)
warehouses	(25, 5)

4.2. Phần A — Khảo sát từng bảng

A0. Tổng quan từng bảng

Khảo sát kích thước, kiểu dữ liệu, tỷ lệ thiếu, số giá trị duy nhất và thống kê mô tả của các cột số.

```
In [2]: def overview(name, df):
        print('='*72)
        print(f'Bảng: {name}.csv | {df.shape[0]} dòng × {df.shape[1]} cột')
        print('-'*72)
        info = pd.DataFrame({
            'dtype': df.dtypes.astype(str),
            'n_unique': df.nunique(),
            'missing_%': (df.isnull().mean()*100).round(2),
        })
        print(info.to_string())

        for f in FILES:
            overview(f, data[f]); print()
```

=====

Bảng: pharmacies.csv | 800 dòng × 8 cột

	dtype	n_unique	missing_%
pharmacy_id	object	800	0.00
pharmacy_type	object	6	5.62
establishment_year	float64	34	4.12
province	object	24	4.12
region	object	3	0.00
onboarding_date	object	698	0.00
acquisition_channel	object	4	4.62
credit_tier	object	3	5.88

=====

Bảng: orders.csv | 3500 dòng × 8 cột

	dtype	n_unique	missing_%
order_id	object	3500	0.00
pharmacy_id	object	690	0.00
warehouse_id	object	25	0.00
order_date	object	1812	0.00
payment_term	object	3	4.97
payment_method	object	4	4.20
discount_applied	float64	6	5.60
order_status	object	4	4.77

=====

Bảng: order_lines.csv | 7740 dòng × 4 cột

	dtype	n_unique	missing_%
order_id	object	3500	0.00
product_id	object	150	0.00
quantity	float64	100	5.05
unit_price	float64	3861	4.95

=====

Bảng: products.csv | 150 dòng × 7 cột

	dtype	n_unique	missing_%
product_id	object	150	0.00
product_name	object	150	0.00
category	object	8	0.00
sub_category	object	24	4.67
manufacturer	object	8	4.67
base_price	float64	141	4.67
drug_type	object	2	0.00

=====

Bảng: support_tickets.csv | 700 dòng × 7 cột

	dtype	n_unique	missing_%
ticket_id	object	700	0.00
pharmacy_id	object	457	0.00
created_date	object	587	0.00
channel	object	5	4.14
issue_type	object	5	5.71
resolution_status	object	3	0.00
satisfaction_score	float64	9	30.00

=====

Bảng: sales_engagements.csv | 1800 dòng × 8 cột

	dtype	n_unique	missing_%
engagement_id	object	1800	0.00
pharmacy_id	object	715	0.00
contact_date	object	1226	0.00
channel	object	5	4.39
engagement_type	object	4	5.28
is_responded	object	4	0.00
is_ordered	int64	2	0.00
offer_value	float64	783	5.33

Bảng: warehouses.csv | 25 dòng x 5 cột

	dtype	n_unique	missing_%
warehouse_id	object	25	0.0
warehouse_name	object	25	0.0
region	object	3	0.0
warehouse_type	object	2	4.0
opened_date	object	25	0.0

```
In [3]: # Thống kê mô tả các cột số: xu hướng trung tâm (mean) và độ biến thiên (std, quartile)
for f in FILES:
    num = data[f].select_dtypes(include='number')
    if num.shape[1]:
        print(f'----- {f}: thống kê mô tả các cột số -----')
        display(num.describe().T[['mean', 'std', 'min', '25%', '50%', '75%', 'max']].round(2))
```

----- pharmacies: thống kê mô tả các cột số -----

	mean	std	min	25%	50%	75%	max
establishment_year	2007.79	19.82	1800.0	2001.0	2009.0	2017.0	2099.0

----- orders: thống kê mô tả các cột số -----

	mean	std	min	25%	50%	75%	max
discount_applied	0.06	0.07	0.0	0.0	0.05	0.1	0.3

----- order_lines: thống kê mô tả các cột số -----

	mean	std	min	25%	50%	75%	max
quantity	24.60	16.10	-50.0	13.0	25.0	38.0	50.0
unit_price	248023.42	143746.29	9600.0	119700.0	244300.0	371300.0	542400.0

----- products: thống kê mô tả các cột số -----

	mean	std	min	25%	50%	75%	max
base_price	248454.55	142245.9	11100.0	121200.0	243100.0	377450.0	474200.0

----- support_tickets: thống kê mô tả các cột số -----

	mean	std	min	25%	50%	75%	max
satisfaction_score	3.04	1.55	-1.0	2.0	3.0	4.0	9.0

----- sales_engagements: thống kê mô tả các cột số -----

	mean	std	min	25%	50%	75%	max
is_ordered	0.24	0.42	0.0	0.0	0.0	0.0	1.0
offer_value	610697.77	667882.61	0.0	0.0	350500.0	1181500.0	2000000.0

```
In [4]: for f in ['pharmacies', 'orders', 'order_lines']:
        print(f'\n----- {f}: một số dòng đầu -----'); display(data[f].head(3))
```

----- pharmacies: một số dòng đầu -----

	pharmacy_id	pharmacy_type	establishment_year	province	region	onboarding_date	acquisition_channel	credit_tier
0	PH0001	Quầy thuốc	2017.0	Đồng Nai	Nam	18/03/2021	Web portal	C
1	PH0002	NaN	2016.0	Khánh Hòa	Trung	2022-01-16	Sales rep	B
2	PH0003	Quầy thuốc	1996.0	An Giang	Nam	2021-04-15	Web portal	B

----- orders: một số dòng đầu -----

	order_id	pharmacy_id	warehouse_id	order_date	payment_term	payment_method	discount_applied	order_status
0	O00001	PH0001	W001	2022-05-10	Net30	Chuyển khoản	0.05	Completed
1	O00002	PH0001	W015	2025-05-06	COD	Tiền mặt	0.00	Completed
2	O00003	PH0001	W022	2022-04-04	COD	Tiền mặt	0.30	Completed

----- order_lines: một số dòng đầu -----

	order_id	product_id	quantity	unit_price
0	O00001	P0031	16.0	74300.0
1	O00001	P0059	3.0	NaN
2	O00002	P0070	48.0	NaN

Nhận xét tổng quan: bảy bảng có tổng cộng khoảng 14.700 dòng, phù hợp với mô tả của đề bài. Một số cột có kiểu dữ liệu chưa đúng, cần xử lý ở các bước sau: các cột ngày đang ở dạng chuỗi, cột `is_responded` ở dạng chuỗi do biểu diễn không đồng nhất, cột `establishment_year` ở dạng số thực. Tỷ lệ thiếu dao động khoảng 4–6% ở hầu hết các cột, riêng `satisfaction_score` thiếu khoảng 30% (phân tích chi tiết ở mục A1).

A1. Giá trị thiếu

Đề bài cho biết dữ liệu có khoảng 5% giá trị thiếu. Sử dụng thư viện `missingno` để khảo sát tỷ lệ, vị trí và mối tương quan giữa các cột bị thiếu, từ đó suy đoán **cơ chế thiếu**.


```
In [5]: rows = []
for f in FILES:
    m = (data[f].isnull().mean()*100).round(2)
    for col, val in m[m > 0].items():
        rows.append({'bảng': f, 'cột': col, 'thiếu_%': val})
miss_tbl = pd.DataFrame(rows).sort_values('thiếu_%', ascending=False).reset_index(drop=True)
miss_tbl
```

```
Out[5]:
```

	bảng	cột	thiếu_%
0	support_tickets	satisfaction_score	30.00
1	pharmacies	credit_tier	5.88
2	support_tickets	issue_type	5.71
3	pharmacies	pharmacy_type	5.62
4	orders	discount_applied	5.60
5	sales_engagements	offer_value	5.33
6	sales_engagements	engagement_type	5.28
7	order_lines	quantity	5.05
8	orders	payment_term	4.97
9	order_lines	unit_price	4.95
10	orders	order_status	4.77
11	products	sub_category	4.67
12	products	base_price	4.67
13	products	manufacturer	4.67
14	pharmacies	acquisition_channel	4.62
15	sales_engagements	channel	4.39
16	orders	payment_method	4.20
17	support_tickets	channel	4.14
18	pharmacies	province	4.12
19	pharmacies	establishment_year	4.12
20	warehouses	warehouse_type	4.00

```
In [6]: # Biểu đồ số Lượng giá trị không thiếu cho TẤT CẢ các bảng (Lưới tự động theo số bảng)
fig, axes = make_grid(len(FILES), h=3.6)
for ax, f in zip(axes, FILES):
    msno.bar(data[f], ax=ax, fontsize=8)
    ax.set_title(f, fontsize=10)
for ax in axes[len(FILES):]:
    ax.axis('off')
plt.suptitle('Số lượng giá trị không thiếu theo cột (từng bảng)', y=1.01)
plt.tight_layout(); plt.show()
```


Số lượng giá trị không thiếu theo cột (từng bảng)



Ma trận `missingno.matrix` thể hiện vị trí giá trị thiếu theo dòng cho từng bảng: các vạch trắng phân bố rải rác gợi ý việc thiếu mang tính ngẫu nhiên, trong khi các vạch trắng tạo thành dải gợi ý việc thiếu có liên hệ giữa các cột.

```
In [7]: fig, axes = make_grid(len(FILEs), h=3.9)
for ax, f in zip(axes, FILEs):
    msno.matrix(data[f], ax=ax, fontsize=7, sparkline=False)
    ax.set_title(f, fontsize=10)
for ax in axes[len(FILEs):]:
    ax.axis('off')
plt.suptitle('Vị trí giá trị thiếu theo dòng (từng bảng)', y=1.005)
plt.tight_layout(); plt.show()
```


Vị trí giá trị thiếu theo dòng (từng bảng)



Ma trận tương quan thiếu (`missingno.heatmap`) đo mức độ hai cột cùng thiếu: giá trị gần **+1** cho thấy hai cột thường thiếu đồng thời (cơ chế MAR/MNAR); giá trị gần **0** cho thấy việc thiếu là độc lập (cơ chế MCAR, có thể điền bằng giá trị đại diện). Chỉ vẽ cho các bảng có từ hai cột thiếu trở lên.

```
In [8]: hm_tables = [f for f in FILES if int((data[f].isnull().mean() > 0).sum()) >= 2]
fig, axes = make_grid(len(hm_tables), h=4.2)
for ax, f in zip(axes, hm_tables):
    msno.heatmap(data[f], ax=ax, fontsize=7, cmap='RdBu')
    ax.set_title(f, fontsize=10)
for ax in axes[len(hm_tables):]:
    ax.axis('off')
plt.suptitle('Tương quan giữa các cột thiếu (từng bảng)', y=1.005)
plt.tight_layout(); plt.show()
skipped = [f for f in FILES if f not in hm_tables]
print('Không vẽ heatmap cho (ít hơn 2 cột thiếu):', skipped)
```

Tương quan giữa các cột thiếu (từng bảng)



Không vẽ heatmap cho (ít hơn 2 cột thiếu): ['warehouses']

```
In [9]: # Bảng chứng định Lượng: tương quan thiếu LỚN NHẤT giữa các cột trong mỗi bảng
# (giá trị nhỏ => các cột thiếu độc lập => thiên về cơ chế MCAR)
summary = []
for f in FILES:
    miss = data[f].isnull()
    cols = miss.columns[miss.any()]
    if len(cols) >= 2:
        cm = miss[cols].astype(int).corr().abs().values
        np.fill_diagonal(cm, 0)
        maxc = round(float(np.nanmax(cm)), 3)
    else:
        maxc = None
    summary.append({'bảng': f, 'số cột có thiếu': int(miss.any().sum()),
                    'tương quan thiếu lớn nhất': maxc})
pd.DataFrame(summary)
```

	bảng	số cột có thiếu	tương quan thiếu lớn nhất
0	pharmacies	5	0.074
1	orders	4	0.026
2	order_lines	2	0.012
3	products	3	0.101
4	support_tickets	3	0.036
5	sales_engagements	3	0.026
6	warehouses	1	NaN

```
In [10]: # Riêng support_tickets: kiểm tra thiếu theo GIÁ TRỊ của cột khác (cơ chế cấu trúc)
st = data['support_tickets']
miss_by_status = (st.assign(score_missing=st['satisfaction_score'].isna())
                  .groupby('resolution_status')['score_missing'].mean().round(3))
print('Tỷ lệ thiếu satisfaction_score theo trạng thái xử lý phiếu:')
print((miss_by_status*100).astype(str) + ' %')
```

Tỷ lệ thiếu satisfaction_score theo trạng thái xử lý phiếu:

resolution_status	
Escalated	100.0 %
Pending	85.6 %
Resolved	5.0 %

Name: score_missing, dtype: object

Kết luận cơ chế thiếu theo từng bảng (dựa trên ma trận, heatmap và bảng tương quan thiếu lớn nhất ở trên):

Bảng	Cơ chế thiếu	Bảng chứng	Hướng xử lý
pharmacies	MCAR	tương quan thiếu giữa các cột gần 0; vạch trắng rải rác	điền trung vị (số) / mode (phân loại)

orders	MCAR	tương quan thiếu gần 0	điền mode / xử lý riêng order_status
order_lines	MCAR	hai cột quantity, unit_price thiếu độc lập	điền sau khi xử lý giá trị âm
products	MCAR	tương quan thiếu gần 0	điền trung vị / mode
support_tickets	Một phần CẤU TRÚC	satisfaction_score thiếu theo giá trị của resolution_status (Escalated 100%, Pending 85.6%, Resolved 5.0%) — heatmap không bắt được vì đây là phụ thuộc theo giá trị, không phải đồng thời thiếu	không điền cho phiếu chưa xử lý xong; chỉ điền ~25 phiếu Resolved thiếu thật
sales_engagements	MCAR	tương quan thiếu gần 0	điền mode / 0 hợp lý
warehouses	MCAR	chỉ 1 cột thiếu (4%)	điền mode

Lưu ý phương pháp: `missingno.heatmap` chỉ phát hiện hiện tượng *thiếu đồng thời* giữa các cột. Riêng cơ chế **thiếu theo thiết kế** của `satisfaction_score` (phụ thuộc vào *giá trị* `resolution_status`, một cột không thiếu) phải được phát hiện bằng phép gộp nhóm (`groupby`) như trên, không thể thấy qua heatmap. Đây là dạng thiếu thứ tư, khác MCAR/MAR/MNAR, và **không được điền** vì sẽ tạo thông tin sai lệch.

A2. Phân phối các biến số


Sử dụng biểu đồ phân phối (histogram) để quan sát độ lệch (skewness) và biểu đồ hộp (boxplot) để phát hiện giá trị ngoại lai.

```
In [11]: # Tự động chọn TẤT CẢ cột số liên tục trên mọi bảng (Loại cờ nhị phân và biến năm),
# in rõ danh sách được vẽ và bị Loại để minh bạch – không chọn tay.
num_cols, excluded = [], []
for f in FILES:
    for c in data[f].select_dtypes(include='number').columns:
        nuniq = data[f][c].nunique()
        if nuniq <= 2:
            excluded.append(f'{f}.{c} (nhị phân -> nhóm phân loại)')
        elif c.endswith('year') or c.endswith('_year'):
            excluded.append(f'{f}.{c} (biến năm -> khảo sát ở A4/A5)')
        else:
            num_cols.append((f, c))
print('Cột số liên tục được vẽ histogram:', [f'{f}.{c}' for f, c in num_cols])
print('Cột số bị loại khỏi nhóm này:', excluded)


fig, axes = make_grid(len(num_cols), h=3.3)
for ax, (f, c) in zip(axes, num_cols):
    s = pd.to_numeric(data[f][c], errors='coerce').dropna()
    ax.hist(s, bins=40, color='#4C72B0', edgecolor='white')
    ax.set_title(f'{f}.{c} (skew={s.skew():.2f})', fontsize=10)
for ax in axes[len(num_cols):]:
    ax.axis('off')
plt.tight_layout(); plt.show()
```

Cột số liên tục được vẽ histogram: ['orders.discount_applied', 'order_lines.quantity', 'order_lines.unit_price', 'products.base_price', 'support_tickets.satisfaction_score', 'sales_engagements.offer_value']

Cột số bị loại khỏi nhóm này: ['pharmacies.establishment_year (biến năm -> khảo sát ở A4/A5)', 'sales_engagements.is_ordered (nhị phân -> nhóm phân loại)']



```
In [12]: # Biểu đồ hộp cho TẤT CẢ cột số liên tục (cùng danh sách num_cols ở trên) để phát hiện ngoại lai
fig, axes = make_grid(len(num_cols), h=3.0)
for ax, (f, c) in zip(axes, num_cols):
    s = pd.to_numeric(data[f][c], errors='coerce').dropna()
    ax.boxplot(s, vert=True); ax.set_title(f'{f}.{c}', fontsize=10); ax.set_xticks([])
for ax in axes[len(num_cols):]:
    ax.axis('off')
plt.tight_layout(); plt.show()
```



```
In [13]: # Bảng tóm tắt phân phối các biến số: độ lệch, tỷ lệ giá trị 0/âm, số mức, ngoại lai IQR
rows = []
for f, c in num_cols:
    s = pd.to_numeric(data[f][c], errors='coerce').dropna()
    q1, q3 = s.quantile(.25), s.quantile(.75); iqr = q3 - q1
    out = int(((s < q1 - 1.5*iqr) | (s > q3 + 1.5*iqr)).sum())
    rows.append({'cột': f'{f}.{c}', 'skew': round(s.skew(), 2),
                '% bằng 0': round((s == 0).mean()*100), '% âm': round((s < 0).mean()*100, 1),
                'số mức': int(s.nunique()), 'ngoại lai IQR': out})
pd.DataFrame(rows)
```

	cột	skew	% bằng 0	% âm	số mức	ngoại lai IQR
0	orders.discount_applied	1.25	48	0.0	6	77
1	order_lines.quantity	-0.63	0	2.1	100	82
2	order_lines.unit_price	0.04	0	0.0	3861	0
3	products.base_price	-0.02	0	0.0	141	0
4	support_tickets.satisfaction_score	0.05	1	0.4	9	1
5	sales_engagements.offer_value	0.63	40	0.0	783	0

Kết luận từ phân phối các biến số:

- **Biến gần đối xứng, không ngoại lai** (`unit_price` skew ≈ 0.04 ; `base_price` skew ≈ -0.02): có thể điền khuyết bằng trung bình, không cần biến đổi.
- **Biến rời rạc hoặc tập trung nhiều giá trị 0** (`discount_applied` chỉ 6 mức, 48% bằng 0; `offer_value` skew 0.63, 40% bằng 0): bản chất là biến rời rạc / tập trung tại 0 — giá trị 0 mang ý nghĩa "không giảm giá / không khuyến mãi", nên điền khuyết bằng trung vị hoặc 0 và cân nhắc biến đổi log, không xem là biến liên tục thuần.
- **Biến chứa lỗi dữ liệu** (`quantity` có 2.1% giá trị âm, nhỏ nhất -50; `satisfaction_score` có giá trị -1 ngoài thang 1-9): cần xử lý ở Bước 2 trước khi sử dụng.
- Tỷ lệ ngoại lai theo IQR đều thấp ($\leq 2.3\%$) và chủ yếu là lỗi nhập (giá trị âm), không phải giá trị cực đoan hợp lệ.

→ **Định hướng cho Bước 2-3:** cột lệch hoặc nhiều ngoại lai dùng trung vị để điền và chuẩn hóa bền (robust) / log; cột đối xứng có thể dùng trung bình.

A3. Phân phối các biến phân loại

Khảo sát tần suất của toàn bộ các biến phân loại trên từng bảng.

```
In [14]: CAT_COLS = [
    ('orders', 'order_status'), ('orders', 'payment_term'), ('orders', 'payment_method'),
    ('products', 'category'), ('products', 'sub_category'), ('products', 'manufacturer'), ('products', 'drug_type'),
    ('pharmacies', 'pharmacy_type'), ('pharmacies', 'region'), ('pharmacies', 'province'),
    ('pharmacies', 'acquisition_channel'), ('pharmacies', 'credit_tier'),
    ('support_tickets', 'channel'), ('support_tickets', 'issue_type'), ('support_tickets', 'resolution_status'),
    ('sales_engagements', 'channel'), ('sales_engagements', 'engagement_type'),
    ('warehouses', 'region'), ('warehouses', 'warehouse_type'),
]
fig, axes = make_grid(len(CAT_COLS), h=3.2)
for ax, (f, c) in zip(axes, CAT_COLS):
    vc = data[f][c].value_counts(dropna=False).head(15)
    vc.index = [str(i) for i in vc.index]
    sns.barplot(x=vc.values, y=vc.index, ax=ax, palette='viridis')
    ax.set_title(f'{f}.{c} ({data[f][c].nunique()} mức)', fontsize=9); ax.set_xlabel('')
for ax in axes[len(CAT_COLS):]: ax.axis('off')
plt.tight_layout(); plt.show()
```



```
In [15]: # Cột is_responded là biến nhị phân nhưng được biểu diễn không đồng nhất
print('sales_engagements.is_responded - các giá trị nguyên thủy:')
print(data['sales_engagements']['is_responded'].value_counts(dropna=False))
```

sales_engagements.is_responded - các giá trị nguyên thủy:

```
is_responded
1      939
0      803
Yes      31
TRUE      27
Name: count, dtype: int64
```

Nhận xét: cột `is_responded` lẽ ra là biến nhị phân (0/1) nhưng được biểu diễn lẫn lộn nhiều dạng ('1' , '0' , 'Yes' , 'TRUE'). Cần quy chuẩn về {0, 1} ở bước làm sạch trước khi sử dụng.

```
In [16]: # Bảng tóm tắt các biến phân loại: số mức (cardinality) và tỷ trọng nhóm phổ biến nhất
rows = []
for f, c in CAT_COLS:
    vc = data[f][c].value_counts(normalize=True)
    rows.append({'cột': f'{f}.{c}', 'số mức': int(data[f][c].nunique()),
                'nhóm phổ biến nhất': str(vc.index[0]), 'tỷ trọng %': round(vc.iloc[0]*100)})
pd.DataFrame(rows).sort_values('số mức', ascending=False).reset_index(drop=True)
```

Out[16]:

	cột	số mức	nhóm phổ biến nhất	tỷ trọng %
0	products.sub_category	24	Khoảng chất	6
1	pharmacies.province	24	Bình Định	5
2	products.manufacturer	8	DHG Pharma	16
3	products.category	8	Kháng sinh	13
4	pharmacies.pharmacy_type	6	Nhà thuốc	45
5	support_tickets.issue_type	5	Công nợ	22
6	sales_engagements.channel	5	Call	26
7	support_tickets.channel	5	Zalo	27
8	pharmacies.acquisition_channel	4	Sales rep	26
9	orders.order_status	4	Completed	80
10	orders.payment_method	4	Tiền mặt	49
11	sales_engagements.engagement_type	4	Thăm trình dược	26
12	orders.payment_term	3	COD	50
13	support_tickets.resolution_status	3	Resolved	71
14	pharmacies.region	3	Trung	35
15	warehouses.region	3	Bắc	36
16	pharmacies.credit_tier	3	B	45
17	products.drug_type	2	OTC	62
18	warehouses.warehouse_type	2	Vệ tinh	75

Kết luận từ phân phối các biến phân loại:

- **Biến có số mức cao (high-cardinality), phân bố phẳng:** `province` (24 tỉnh, nhóm lớn nhất chỉ 5%) và `sub_category` (24 nhóm, lớn nhất 6%). Mã hóa one-hot sẽ tạo rất nhiều cột thừa; kết hợp mô hình tuyến tính và phân chia theo thời gian để phát sinh tình trạng một mức chỉ xuất hiện ở một tập. **Định hướng (Bước 3):** ưu tiên dùng `region` (3 mức) thay cho `province`; gộp các nhóm hiếm của `sub_category` và `manufacturer`.
- **Biến có một nhóm áp đảo:** `order_status` (Completed khoảng 77% tổng đơn), `drug_type` (OTC 62%), `resolution_status` (Resolved 71%, tức khoảng 29% phiếu chưa đóng — phù hợp với phần thiếu mang tính cấu trúc của `satisfaction_score`), `warehouse_type` (Vệ tinh 75%).
- **Biến phân bố tương đối đều** (`region`, `credit_tier`, `payment_term`, các kênh liên hệ): phù hợp mã hóa one-hot trực tiếp.

→ **Định hướng cho Bước 2.5–3:** dùng one-hot cho biến ít mức; gộp hoặc thay thế cho biến nhiều mức; cột `order_status` được dùng để lọc đơn hợp lệ.

A4. Biến thời gian

Đây là nhóm biến quan trọng do đề bài yêu cầu phân chia dữ liệu theo thời gian. Cần kiểm tra định dạng ngày, bởi cùng một cột có thể chứa nhiều định dạng khác nhau.

```
In [17]: def sniff_date_format(series):
    out = {}
    for v in series.dropna().astype(str):
        if re.match(r'^\d{4}-\d{2}-\d{2}$', v): k='YYYY-MM-DD'
        elif re.match(r'^\d{1,2}/\d{1,2}/\d{4}$', v): k='DD/MM/YYYY'
        elif re.match(r'^\d{4}-\d{1,2}-\d{4}$', v): k='MM-DD-YYYY'
        else: k='Khác'
        out[k] = out.get(k,0)+1
    return out

date_cols = {'orders':'order_date','pharmacies':'onboarding_date',
```

```

'support_tickets':'created_date','sales_engagements':'contact_date','warehouses':'opened_date'})
for f,c in date_cols.items():
    print(f'{f}.{:16s} -> {sniff_date_format(data[f][c])}')

```

```

orders.order_date      -> {'YYYY-MM-DD': 2806, 'DD/MM/YYYY': 425, 'MM-DD-YYYY': 269}
pharmacies.onboarding_date -> {'DD/MM/YYYY': 90, 'YYYY-MM-DD': 648, 'MM-DD-YYYY': 62}
support_tickets.created_date -> {'YYYY-MM-DD': 559, 'DD/MM/YYYY': 81, 'MM-DD-YYYY': 60}
sales_engagements.contact_date -> {'MM-DD-YYYY': 143, 'YYYY-MM-DD': 1428, 'DD/MM/YYYY': 229}
warehouses.opened_date -> {'YYYY-MM-DD': 23, 'DD/MM/YYYY': 2}

```

```

In [18]: def parse_mixed_date(series):
    '''Phân tích ngày đa định dạng: dấu "/" theo %d/%m/%Y, dấu "-" theo %m-%d-%Y.
    Hai định dạng dùng dấu phân tách khác nhau nên không gây nhầm lẫn ngày/tháng.'''
    s = series.astype(str).str.strip()
    o = pd.to_datetime(s, format='%Y-%m-%d', errors='coerce')
    m = o.isna(); o[m] = pd.to_datetime(s[m], format='%d/%m/%Y', errors='coerce')
    m = o.isna(); o[m] = pd.to_datetime(s[m], format='%m-%d-%Y', errors='coerce')
    return o

print('Khoảng thời gian sau khi chuẩn hóa (giá trị lớn nhất phản ánh cửa sổ dữ liệu):')
for f,c in date_cols.items():
    d = parse_mixed_date(data[f][c])
    print(f' {f}.{:16s}: {d.min().date()} đến {d.max().date()} | không phân tích được: {d.isna().sum()}')

```

```


Khoảng thời gian sau khi chuẩn hóa (giá trị lớn nhất phản ánh cửa sổ dữ liệu):
orders.order_date      : 2020-01-22 đến 2025-12-31 | không phân tích được: 0
pharmacies.onboarding_date : 2020-01-01 đến 2025-06-28 | không phân tích được: 0
support_tickets.created_date : 2020-03-17 đến 2025-12-31 | không phân tích được: 0
sales_engagements.contact_date : 2020-01-08 đến 2025-12-31 | không phân tích được: 0
warehouses.opened_date : 2015-01-21 đến 2022-11-14 | không phân tích được: 0

```

```

In [19]: od_dates = parse_mixed_date(data['orders']['order_date']).dropna()
monthly = od_dates.dt.to_period('M').value_counts().sort_index()
monthly.index = monthly.index.astype(str)
plt.figure(figsize=(14, 4))
plt.plot(monthly.index, monthly.values, marker='o', ms=3)
plt.xticks(rotation=90, fontsize=7); plt.title('Số lượng đơn hàng theo tháng')
plt.ylabel('Số đơn'); plt.tight_layout(); plt.show()

```



```

In [20]: # Kiểm tra ràng buộc logic của biến thời gian sau khi chuẩn hóa
ph = data['pharmacies'].copy(); od = data['orders'].copy()
ph['onb'] = parse_mixed_date(ph['onboarding_date'])
ph['est'] = pd.to_numeric(ph['establishment_year'], errors='coerce')
od['d'] = parse_mixed_date(od['order_date'])
mg = od.merge(ph[['pharmacy_id','onb']], on='pharmacy_id', how='left')

checks = [
    ['Đơn hàng phát sinh trước ngày onboarding', int((mg['d'] < mg['onb']).sum())],
    ['Đơn hàng có ngày trong tương lai', int((od['d'] > REF_DATE).sum())],
    ['Năm thành lập sau năm onboarding (không hợp lệ)',
     int((ph.loc[ph['onb'].notna() & ph['est'].notna(), 'est']
            > ph.loc[ph['onb'].notna() & ph['est'].notna(), 'onb'].dt.year).sum())],
]
pd.DataFrame(checks, columns=['Ràng buộc logic của biến thời gian', 'Số dòng vi phạm'])

```

Out[20]:

	Ràng buộc logic của biến thời gian	Số dòng vi phạm
0	Đơn hàng phát sinh trước ngày onboarding	0
1	Đơn hàng có ngày trong tương lai	0
2	Năm thành lập sau năm onboarding (không hợp lệ)	3

Kết luận về biến thời gian:

- Mỗi cột ngày chứa đồng thời ba định dạng (YYYY-MM-DD chiếm đa số, cùng DD/MM/YYYY và MM-DD-YYYY); hàm `parse_mixed_date()` chuẩn hóa được toàn bộ, không còn giá trị không phân tích được.

- Dữ liệu trải dài từ năm 2020 đến hết **2025-12-31** ở cả ba bảng có yếu tố thời gian (orders, support_tickets, sales_engagements). Mốc kết thúc chung này xác định **cửa sổ rò rỉ thời gian**: khi xây dựng nhãn và đặc trưng cần cắt theo mốc T trên *mọi* bảng, không riêng orders.
- Kiểm tra ràng buộc logic: không có đơn hàng phát sinh trước ngày onboarding hay đơn hàng trong tương lai; tồn tại 3 dòng có năm thành lập (2030, 2099) sau năm onboarding — các giá trị này đồng thời nằm ngoài khoảng năm hợp lệ, nên được xử lý chung ở Bước 2.

A5. Giá trị ngoại lai và ràng buộc miền giá trị

Ngoài ngoại lai theo nghĩa thống kê (IQR), cần kiểm tra **ràng buộc miền giá trị theo ngữ nghĩa**. Hai loại này khác nhau: ví dụ giá trị `establishment_year = 2099` vẫn nằm trong khoảng phổ biến (IQR không phát hiện) nhưng vô lý về mặt logic — đây thực chất là giá trị thiếu ngụy trang (disguised-missing). Do đó sử dụng biên động [1900, năm hiện tại] kết hợp ràng buộc theo ngày onboarding.

```
In [21]: REF_YEAR = REF_DATE.year
rows = []
ol = data['order_lines']
q = pd.to_numeric(ol['quantity'], errors='coerce')
rows.append(['order_lines.quantity', 'Số lượng âm', int((q<0).sum()), f'min={q.min()}'])
up = pd.to_numeric(ol['unit_price'], errors='coerce')
rows.append(['order_lines.unit_price', 'Giá trị âm', int((up<0).sum()), f'min={up.min()}'])
sat = pd.to_numeric(data['support_tickets']['satisfaction_score'], errors='coerce')
rows.append(['support_tickets.satisfaction_score', 'Ngoài thang 1-5', int((sat.notna() & ~sat.between(1,5)).sum()), f'min={sat.min()}'])
ey = pd.to_numeric(data['pharmacies']['establishment_year'], errors='coerce')
rows.append(['pharmacies.establishment_year', f'Ngoài khoảng [1900, {REF_YEAR}]', int(((ey<1900)|(ey>REF_YEAR)).sum()), f'min={ey.min()}'])
disc = pd.to_numeric(data['orders']['discount_applied'], errors='coerce')
rows.append(['orders.discount_applied', 'Ngoài khoảng [0, 1]', int(((disc<0)|(disc>1)).sum()), f'min={disc.min()}, max={disc.max()}'])
pd.DataFrame(rows, columns=['Cột', 'Loại vi phạm', 'Số dòng', 'Chi tiết'])
```

	Cột	Loại vi phạm	Số dòng	Chi tiết
0	order_lines.quantity	Số lượng âm	157	min=-50.0
1	order_lines.unit_price	Giá trị âm	0	min=9600.0
2	support_tickets.satisfaction_score	Ngoài thang 1-5	11	min=-1.0, max=9.0, các giá trị lạ: -1,0,7,9
3	pharmacies.establishment_year	Ngoài khoảng [1900, 2026]	7	min=1800.0, max=2099.0
4	orders.discount_applied	Ngoài khoảng [0, 1]	0	min=0.0, max=0.3

Kết luận về ngoại lai và miền giá trị: phát hiện các vi phạm cần xử lý ở Bước 2 — `quantity` có 157 giá trị âm (lỗi nhập). Cột `satisfaction_score` có **thang hợp lệ 1-5** (khối chính khoảng 479 phiếu dồn ở 1-5, sau đó rớt hẳn); các giá trị **-1, 0, 7, 9** (tổng 11 dòng) nằm ngoài thang, là nhiễu cần loại. Cột `establishment_year` có giá trị ngoài khoảng hợp lệ (như 1800, 2030, 2099 — giá trị thiếu ngụy trang (disguised-missing)). Các cột `unit_price`, `base_price`, `discount_applied` đều nằm trong miền hợp lệ.

A6. Kiểm tra ràng buộc logic

Đề bài nêu rõ một số ràng buộc logic cần kiểm tra giữa các cột.

```
In [22]: se = data['sales_engagements'].copy()
resp_map = {'1':1,'0':0,'Yes':1,'TRUE':1,'True':1,'No':0,'FALSE':0}
se['resp_norm'] = se['is_responded'].astype(str).map(resp_map)
print(f'[1] is_ordered = 1 nhưng is_responded = 0 (đặt hàng khi chưa phản hồi): {(se["is_ordered"]==1)&(se["resp_norm"]==0).sum()} dòng')

st = data['support_tickets']; sat = pd.to_numeric(st['satisfaction_score'], errors='coerce')
open_mask = st['resolution_status'].isin(['Pending','Escalated'])
print(f'[2] Phiếu Pending/Escalated nhưng có điểm hài lòng (không hợp lệ): {(open_mask & sat.notna()).sum()} dòng')
print(f'[3] Phiếu Resolved nhưng thiếu điểm hài lòng (thiếu thực sự): {(~open_mask & sat.isna()).sum()} dòng')
```

[1] is_ordered = 1 nhưng is_responded = 0 (đặt hàng khi chưa phản hồi): 41 dòng
 [2] Phiếu Pending/Escalated nhưng có điểm hài lòng (không hợp lệ): 19 dòng
 [3] Phiếu Resolved nhưng thiếu điểm hài lòng (thiếu thực sự): 25 dòng

Kết luận về ràng buộc logic: dữ liệu có một số mâu thuẫn nội tại cần hiệu chỉnh ở Bước 2 — 41 bản ghi đặt hàng khi chưa phản hồi (`is_ordered = 1` nhưng `is_responded = 0`), và 19 phiếu chưa xử lý xong nhưng đã có điểm hài lòng. Riêng 25 phiếu `Resolved` thiếu điểm là giá trị thiếu thực sự, khác với phần thiếu mang tính cấu trúc đã phân tích ở mục A1.

A7. Trùng lặp, khóa và tính nhất quán

Kiểm tra bản ghi trùng lặp (toàn dòng và theo khóa tổ hợp), khoảng trống thừa trong biến phân loại, và tính nhất quán của giá trị giữa các bảng.

```
In [23]: ol = data['order_lines']
print('Số bản ghi trùng lặp toàn dòng:')
for f in FILES:
```

```

print(f' {f:18s}: {data[f].duplicated().sum()}')
print(f'order_lines - trùng theo khóa tổ hợp (order_id, product_id): {ol.duplicated(["order_id", "product_id"]).sum()}')

ws = 0
for f, c in CAT_COLS:
    s = data[f][c].dropna().astype(str)
    ws += int((s != s.str.strip()).sum())
print(f'Tổng số giá trị phân loại có khoảng trắng thừa: {ws} (giá trị 0 nghĩa là không có)')

print('Giá trị region trong pharmacies:', sorted(data['pharmacies']['region'].dropna().unique()))
print('Giá trị region trong warehouses:', sorted(data['warehouses']['region'].dropna().unique()))

```

Số bản ghi trùng lặp toàn dòng:

```

pharmacies      : 0
orders          : 0
order_lines     : 0
products       : 0
support_tickets : 0
sales_engagements : 0
warehouses     : 0

```

order_lines - trùng theo khóa tổ hợp (order_id, product_id): 0


Tổng số giá trị phân loại có khoảng trắng thừa: 0 (giá trị 0 nghĩa là không có)

Giá trị region trong pharmacies: ['Bắc', 'Nam', 'Trung']

Giá trị region trong warehouses: ['Bắc', 'Nam', 'Trung']

Kết luận về trùng lặp và nhất quán: không có bản ghi trùng toàn dòng hay trùng theo khóa tổ hợp, không có khoảng trắng thừa trong biến phân loại, và giá trị **region** nhất quán giữa hai bảng pharmacies và warehouses. Các trục chất lượng dữ liệu này đạt yêu cầu, không cần xử lý thêm.

4.3. Sơ đồ quan hệ thực thể (ERD) và khóa nối



Quan hệ giữa các bảng (bản số):

- pharmacies (1) – orders (n); orders (n) – warehouses (1)
- orders (1) – order_lines (n); order_lines (n) – products (1)
- pharmacies (1) – support_tickets (n); pharmacies (1) – sales_engagements (n)

Grain mục tiêu là **một dòng tương ứng một nhà thuốc** (ảnh chụp tại mốc thời gian T). Do đó các bảng con (orders, support_tickets, sales_engagements) cần được tổng hợp về mức nhà thuốc trước khi nối (thực hiện ở Bước 2.5).

Chiến lược nối bảng (LEFT JOIN và INNER JOIN)

Nguyên tắc: dùng **LEFT JOIN** khi cần giữ toàn bộ bản ghi của bảng gốc (kể cả bản ghi không khớp); dùng **INNER JOIN** khi chỉ giữ các bản ghi khớp ở cả hai bảng.

Phép nối	Loại	Lý do lựa chọn
order_lines → products	LEFT	Giữ mọi dòng chi tiết đơn để tính total_amount
order_lines → orders	INNER	Mỗi dòng chi tiết phải thuộc một đơn hàng hợp lệ
orders → warehouses	LEFT	Giữ mọi đơn hàng kể cả khi thiếu thông tin kho
pharmacies → orders/tickets/engagements (đã tổng hợp)	LEFT	Giữ toàn bộ nhà thuốc, bao gồm nhà thuốc chưa phát sinh đơn và nhóm bị censoring; sau khi nối, điền 0 cho các giá trị đếm bị thiếu

Lưu ý: nếu dùng INNER JOIN ở phép nối cuối (pharmacies với orders) sẽ loại bỏ các nhà thuốc chưa phát sinh đơn hàng, dẫn đến tính sai mức độ censoring. Do đó cần dùng LEFT JOIN rồi điền 0.

4.4. Phần B — Quan hệ giữa các bảng

B1. Tính toàn vẹn khóa

Kiểm tra tính duy nhất của khóa chính và sự tồn tại của khóa ngoại (orphan foreign key) để bảo đảm phép nối không làm mất dòng ngoài ý muốn.

```
In [24]: ph_, od_, wh_, pr_ = data['pharmacies'], data['orders'], data['warehouses'], data['products']
print('Tính duy nhất của khóa chính:')
print(f' pharmacies.pharmacy_id: {ph_["pharmacy_id"].is_unique}')
print(f' orders.order_id      : {od_["order_id"].is_unique}')
print('\nKhóa ngoại không tồn tại trong bảng tham chiếu (giá trị 0 là tốt):')
print(f' order_lines.order_id không có trong orders      : {len(set(od_["order_id"])) - set(od_["order_id"])}')
print(f' order_lines.product_id không có trong products : {len(set(od_["product_id"])) - set(pr_["product_id"])}')
print(f' orders.pharmacy_id không có trong pharmacies   : {len(set(od_["pharmacy_id"])) - set(ph_["pharmacy_id"])}')
print(f' orders.warehouse_id không có trong warehouses  : {len(set(od_["warehouse_id"])) - set(wh_["warehouse_id"])}')
```

Tính duy nhất của khóa chính:
pharmacies.pharmacy_id: True
orders.order_id : True

Khóa ngoại không tồn tại trong bảng tham chiếu (giá trị 0 là tốt):
order_lines.order_id không có trong orders : 0
order_lines.product_id không có trong products : 0
orders.pharmacy_id không có trong pharmacies : 0
orders.warehouse_id không có trong warehouses : 0

Nhận xét: khóa chính của các bảng đều duy nhất và không tồn tại khóa ngoại lạc (orphan foreign key). Do đó các phép nối ở Bước 2.5 sẽ không làm mất dòng ngoài ý muốn; việc lựa chọn LEFT hay INNER JOIN (xem mục 4.3) là theo chủ đích phân tích, không phải để tránh mất dữ liệu.

B2. Hiện tượng censoring

Bài toán tái đặt hàng chỉ nên tính trên **đơn hàng hợp lệ** (trạng thái `Completed`). Các đơn `Cancelled`, `Returned`, `Pending` không phản ánh hành vi mua thực sự, nếu đưa vào sẽ làm sai lệch khoảng cách giữa các đơn và nhân mục tiêu. Bảng dưới đây so sánh mức độ censoring khi tính trên toàn bộ trạng thái và khi chỉ tính đơn hợp lệ.


```
In [25]: def censor_groups(orders_df, label):
    oc = orders_df.groupby('pharmacy_id')['order_id'].nunique()
    n = data['pharmacies']['pharmacy_id'].nunique()
    n0 = n - oc.index.nunique(); n1 = int((oc==1).sum()); n2 = int((oc>=2).sum())
    return pd.Series({'0 đơn':n0, '1 đơn (bị censoring)':n1, 'từ 2 đơn trở lên':n2,
                      'tỷ lệ censoring %': round((n0+n1)/n*100,1)}, name=label)

cmp = pd.concat([
    censor_groups(od_, 'Toàn bộ trạng thái'),
    censor_groups(od_[od_['order_status']=='Completed'], 'Chỉ đơn Completed'),
], axis=1)
print(cmp.to_string())
print('\nNhận xét: khi chỉ tính đơn hợp lệ (Completed), tỷ lệ nhà thuốc bị censoring tăng từ 28.5% lên 35.5%')
print('Bài toán tái đặt hàng cần sử dụng đơn Completed; vấn đề này được xử lý ở Bước 4.5.')

g = censor_groups(od_[od_['order_status']=='Completed'], 'Completed')
plt.figure(figsize=(6,4))
sns.barplot(x=['0 đơn', '1 đơn\n(bị censoring)', '≥ 2 đơn'],
            y=[g['0 đơn'], g['1 đơn (bị censoring)'], g['từ 2 đơn trở lên']], palette='rocket')
plt.title('Phân nhóm nhà thuốc theo số đơn hợp lệ (Completed)')
plt.ylabel('Số nhà thuốc'); plt.tight_layout(); plt.show()
```

	Toàn bộ trạng thái	Chỉ đơn Completed
0 đơn	110.0	145.0
1 đơn (bị censoring)	118.0	139.0
từ 2 đơn trở lên	572.0	516.0
tỷ lệ censoring %	28.5	35.5

Nhận xét: khi chỉ tính đơn hợp lệ (Completed), tỷ lệ nhà thuốc bị censoring tăng từ 28.5% lên 35.5%. Bài toán tái đặt hàng cần sử dụng đơn Completed; vấn đề này được xử lý ở Bước 4.5.



4.5. Phần C — Khảo sát theo định hướng mô hình

Do đề bài yêu cầu chỉ sử dụng mô hình tuyến tính và phân chia dữ liệu theo thời gian, phần này tập trung vào hai nội dung: **multicollinearity** (ảnh hưởng tới việc diễn giải hệ số) và **drift** theo thời gian.

```
In [26]: # Khảo sát sơ bộ tương quan giữa các cột số thô. Phân tích multicollinearity đầy đủ
# (ví dụ corr(Frequency, Monetary)) sẽ được thực hiện ở Bước 4 sau khi tạo đặc trưng RFM.
num_pair = pd.concat([
    pd.to_numeric(data['order_lines']['quantity'], errors='coerce'),
    pd.to_numeric(data['order_lines']['unit_price'], errors='coerce'),
], axis=1)
print('Tương quan giữa quantity và unit_price (order_lines):')
print(num_pair.corr().round(3))
print('\nGhi chú: phân tích multicollinearity đầy đủ giữa các đặc trưng (ví dụ Frequency và Monetary)')
print('sẽ được thực hiện ở Bước 4 sau khi các đặc trưng được tạo, theo tinh thần EDA lặp.')
```

Tương quan giữa quantity và unit_price (order_lines):


	quantity	unit_price
quantity	1.000	0.011
unit_price	0.011	1.000

Ghi chú: phân tích multicollinearity đầy đủ giữa các đặc trưng (ví dụ Frequency và Monetary) sẽ được thực hiện ở Bước 4 sau khi các đặc trưng được tạo, theo tinh thần EDA lặp.

```
In [27]: # Drift: so sánh giai đoạn đầu (huấn luyện) và giai đoạn cuối (kiểm tra)
od2 = data['orders'].copy(); od2['d'] = parse_mixed_date(od2['order_date'])
od2 = od2.dropna(subset=['d']).sort_values('d')
cut = od2['d'].quantile(0.8)
early, late = od2[od2['d'] <= cut], od2[od2['d'] > cut]
print(f'Mốc thời gian cắt (80% dữ liệu): {cut.date()} | giai đoạn đầu: {len(early)} đơn, giai đoạn cuối: {len(late)} đơn')

fig, axes = plt.subplots(1, 2, figsize=(14,4))
ax = axes[0]
ax.hist(pd.to_numeric(early['discount_applied'], errors='coerce').dropna(), bins=15, alpha=.6, label='giai đoạn đầu', d
ax.hist(pd.to_numeric(late['discount_applied'], errors='coerce').dropna(), bins=15, alpha=.6, label='giai đoạn cuối', d
ax.set_title('Drift: discount_applied'); ax.legend()
ax = axes[1]
e = early['order_status'].value_counts(normalize=True); l = late['order_status'].value_counts(normalize=True)
pd.DataFrame({'giai đoạn đầu': e, 'giai đoạn cuối': l}).fillna(0).plot(kind='bar', ax=ax)
ax.set_title('Drift: order_status'); plt.tight_layout(); plt.show()
```

Mốc thời gian cắt (80% dữ liệu): 2025-08-04 | giai đoạn đầu: 2801 đơn, giai đoạn cuối: 699 đơn



Trạng thái Phần C (theo tinh thần EDA là quá trình lặp):

- *Multicollinearity*: khảo sát sơ bộ ở đây, hoàn thiện ở mục 9 sau khi tạo đặc trưng — kết quả: `corr(frequency, monetary) = 0.934`, $VIF \approx 19$ (multicollinearity nghiêm trọng), sẽ xử lý bằng bỏ/gộp đặc trưng hoặc hồi quy Ridge ở Bước 6.
- *Cân bằng lớp*: xác định ở Bước 4.5 — lớp dương `will_reorder_45` chiếm **18.2%** (mất cân bằng khoảng 4:1).
- *Liên hệ đặc trưng–nhân* (mục 9): nhóm RFM và `interval_mean` có ý nghĩa thống kê với nhân; trong khi **toàn bộ đặc trưng hỗ trợ và tiếp thị không có ý nghĩa** ($p > 0.08$) nên được giữ ở mức gọn — một phát hiện định hướng việc chọn đặc trưng.
- *Drift*: đã so sánh giai đoạn đầu và cuối ở trên, làm cơ sở cho việc phân chia dữ liệu theo thời gian ở Bước 5.

4.6. Tổng hợp các vấn đề dữ liệu phát hiện được

Bảng dưới đây tổng hợp các vấn đề phát hiện trong quá trình EDA, làm đầu vào cho bước làm sạch (Bước 2) và các bước sau.

#	Bảng / Cột	Vấn đề	Hướng xử lý
1	orders.order_status	Các đơn Cancelled/Returned/Pending (khoảng 9.9% trở lên) không phản ánh giao dịch thực sự	Chỉ sử dụng đơn <code>Completed</code> khi tính khoảng cách, độ gần đây, doanh số và nhân (Bước 2.5, 4.5)
2	Nhiều cột (5/7 bảng)	Thiếu khoảng 4–6% (cơ chế MCAR)	Điền bằng trung vị (biến số) hoặc mode (biến phân loại), ước lượng trên tập huấn luyện
3	order_lines.quantity	157 dòng có giá trị âm (nhỏ nhất −50)	Lấy giá trị tuyệt đối hoặc gán thiếu rồi điền
4	support_tickets.satisfaction_score	Giá trị âm (−1) và thiếu 30% (phần lớn có tính cấu trúc)	Gán giá trị âm thành thiếu; không điền cho phiếu chưa xử lý xong
5	sales_engagements.is_responded	Biểu diễn nhị phân không đồng nhất (1/0/Yes/TRUE)	Quy chuẩn về {0, 1}
6	pharmacies.establishment_year	Giá trị 1800 và 2099 (thiếu nguy trang, disguised-missing)	Giới hạn trong [1900, năm hiện tại] và ràng buộc theo ngày onboarding (3 dòng)
7	Bốn cột ngày	Lẫn ba định dạng khác nhau	Chuẩn hóa bằng hàm <code>parse_mixed_date()</code>
8	is_ordered và is_responded	41 dòng vi phạm ràng buộc logic	Hiệu chỉnh <code>is_responded = 1</code> khi <code>is_ordered = 1</code>
9	satisfaction_score và resolution_status	19 dòng phiếu chưa xử lý xong nhưng có điểm	Gán điểm thành thiếu
10	Toàn vẹn khóa	Không có khóa ngoại lạc	Phép nối an toàn
11	pharmacies (theo đơn hợp lệ)	Tỷ lệ censoring 35.5% (tính trên đơn Completed, không phải 28.5%)	Xử lý ở Bước 4.5 theo ba nhóm và nêu rõ trong báo cáo

Kết quả EDA phù hợp với mô tả của đề bài: khoảng 5% giá trị thiếu, khoảng 3% giá trị nhiễu, ngày tháng nhiều định dạng và một số ràng buộc logic bị vi phạm. Các nội dung này được xử lý ở **Bước 2 — Làm sạch dữ liệu**.

5. Bước 2 — Làm sạch dữ liệu

Việc làm sạch được chia thành hai loại theo nguy cơ rò rỉ dữ liệu (data leakage):

- **Thao tác tất định (deterministic)**: biến đổi từng dòng, **không ước lượng tham số từ phân phối dữ liệu** (chuẩn hóa ngày, quy chuẩn biến nhị phân, lấy trị tuyệt đối giá trị âm, đưa giá trị vô lý về `NaN`, hiệu chỉnh ràng buộc logic, loại bản ghi trùng). Các thao tác này được thực hiện **ngay tại bước này** vì không gây rò rỉ.
- **Điền khuyết dựa trên phân phối (trung vị / mode)**: là tham số học từ dữ liệu, nên được **hoãn lại và đưa vào Pipeline**, **ước lượng chỉ trên tập huấn luyện** (Bước 5–6). Tại bước này chỉ chuẩn hóa biểu diễn của giá trị thiếu (đưa giá trị vô lý / disguised-missing về `NaN`) để bộ điền khuyết xử lý sau.

Dữ liệu thô được giữ nguyên trong `data`; bản đã làm sạch lưu trong `clean`.

Chiến lược xử lý từng vấn đề (kèm lý do):

Vấn đề (từ EDA)	Chiến lược	Lý do
Bốn cột ngày lẫn ba định dạng	<code>parse_mixed_date()</code> → <code>datetime</code>	Cần <code>datetime</code> để tính khoảng cách thời gian và phân chia theo thời gian; phân biệt theo dấu phân tách để không nhầm ngày/tháng
<code>is_responded</code> lẫn 1/0/Yes/TRUE	Ánh xạ về {0, 1}	Biến nhị phân phải đồng nhất mới kiểm tra logic và đưa vào mô hình
<code>quantity</code> có 157 giá trị âm	Lấy trị tuyệt đối	Giá định lỗi nhập dấu; giữ lại giá trị để tính <code>total_amount</code> . Nếu coi là hỏng hoàn toàn thì thay bằng đưa về <code>NaN</code> rồi điền
<code>satisfaction_score</code> ngoài thang 1–5 (các giá trị −1, 0, 7, 9 — tổng 11 dòng)	Đưa về <code>NaN</code>	Thang hợp lệ là 1–5 (khối chính dồn ở 1–5 rồi rớt hẳn); 0/7/9/−1 là nhiễu ngoài thang

satisfaction_score của vé Pending/Escalated	Đưa về NaN + cờ satisfaction_observed , không điền	Thiếu theo thiết kế (structural); điền sẽ tạo thông tin sai lệch
establishment_year ngoài [1900, năm nay]	Đưa về NaN	Giá trị vô lý / thiếu nguy trang (disguised-missing)
establishment_year lớn hơn năm onboarding	Đưa về NaN (kiểm tra phòng vệ)	Không thể thành lập sau khi đã onboard; trong dữ liệu này 3 dòng đó (2030, 2099) đã nằm trong nhóm ngoài biên, không thêm dòng mới
is_ordered =1 nhưng is_responded =0 (41 dòng, 2.3%)	Đặt is_responded =1 và thêm cờ flag_logic_fixed	Không thể kiểm chứng từ bảng orders (cờ is_ordered chỉ khoảng 12% có đơn Completed thật theo sau, kể cả các dòng hợp lệ → đây là mẫu thuần cờ-với-cờ). Chọn sửa is_responded để giữ ràng buộc và không xóa tín hiệu đặt hàng (biến hiếm, gần nhân nhất); nếu đặt is_ordered =0 sẽ hủy tín hiệu này
Bản ghi trùng	drop_duplicates	Tránh đếm trùng
Điền khuyết trung vị / mode	Hoãn vào Pipeline , fit trên train	Là tham số học từ dữ liệu, fit trên cả tập sẽ gây rò rỉ
Đơn Cancelled / Returned / Pending	Giữ lại, chưa lọc	Vẫn là đặc trưng tiềm năng (tỷ lệ hủy, tỷ lệ trả hàng); chỉ lọc khi tính khoảng cách/nhân ở Bước 4-4.5

5.1. Chuẩn hóa kiểu dữ liệu (ngày và biến nhị phân)

```
In [28]: clean = {f: data[f].copy() for f in FILES}

# (1) Chuẩn hóa ngày: áp dụng parse_mixed_date cho mọi cột ngày
DATE_COLS = {'orders': ['order_date'], 'pharmacies': ['onboarding_date'],
              'support_tickets': ['created_date'], 'sales_engagements': ['contact_date'],
              'warehouses': ['opened_date']}
for f, cols in DATE_COLS.items():
    for c in cols:
        clean[f][c] = parse_mixed_date(clean[f][c])

# (2) Quy chuẩn biến nhị phân is_responded về {0, 1}
resp_map = {'1': 1, '0': 0, '1': 1, '0': 0, 'Yes': 1, 'No': 0,
            'TRUE': 1, 'True': 1, 'FALSE': 0, 'False': 0}
clean['sales_engagements']['is_responded'] = clean['sales_engagements']['is_responded'].map(resp_map)

print('Sau chuẩn hóa kiểu dữ liệu:')
print(' order_date dtype      : ', clean['orders']['order_date'].dtype)
print(' is_responded giá trị : ', sorted(clean['sales_engagements']['is_responded'].dropna().unique().tolist()))

Sau chuẩn hóa kiểu dữ liệu:
order_date dtype      : datetime64[ns]
is_responded giá trị : [0, 1]
```

5.2. Hiệu chỉnh giá trị không hợp lệ và ràng buộc logic

```
In [29]: audit = []

# (3) quantity âm -> Lấy trị tuyệt đối
ol = clean['order_lines']
q = pd.to_numeric(ol['quantity'], errors='coerce')
n_neg = int((q < 0).sum())
ol['quantity'] = q.abs()
ol['unit_price'] = pd.to_numeric(ol['unit_price'], errors='coerce')
audit.append(['order_lines.quantity', 'Lấy trị tuyệt đối', 'Giả định lỗi nhập dấu; giữ giá trị để tính total_amount',

# (4) satisfaction_score: ngoài thang 1-5 -> NaN; phiếu chưa đóng có điểm -> NaN; thêm cờ quan sát được
# Thang hợp lệ là 1-5 (xem phân phối ở A5): các giá trị -1, 0, 7, 9 là nhiễu ngoài thang.
st = clean['support_tickets']
sat = pd.to_numeric(st['satisfaction_score'], errors='coerce')
n_invalid = int((sat.notna() & ~sat.between(1, 5)).sum())
sat = sat.where(sat.between(1, 5))
open_mask = st['resolution_status'].isin(['Pending', 'Escalated'])
n_open_score = int((open_mask & sat.notna()).sum())
sat = sat.mask(open_mask)
st['satisfaction_score'] = sat
st['satisfaction_observed'] = (~open_mask).astype(int) # 1: phiếu đã đóng (điểm hợp lệ nếu có)
audit.append(['support_tickets.satisfaction_score', 'Ngoài thang 1-5 -> NaN', 'Thang hợp lệ 1-5; -1/0/7/9 là nhiễu', n
audit.append(['support_tickets.satisfaction_score', 'Phiếu chưa đóng có điểm -> NaN', 'Mẫu thuần logic: chỉ có điểm kh

# (5) establishment_year: ngoài [1900, năm nay] HOẶC Lớn hơn năm onboarding -> NaN
ph = clean['pharmacies']
ey = pd.to_numeric(ph['establishment_year'], errors='coerce')
onb_year = ph['onboarding_date'].dt.year
mask_oob = (ey < 1900) | (ey > REF_YEAR)
```

```
mask_gt = ey.notna() & onb_year.notna() & (ey > onb_year)
n_oob = int(mask_oob.sum())
n_gt_new = int((mask_gt & ~mask_oob).sum()) # chỉ đếm dòng MỖI ngoài nhóm đã bắt bởi biên
ph['establishment_year'] = ey.where(~(mask_oob | mask_gt))
audit.append(['pharmacies.establishment_year', f'Ngoài [1900, {REF_YEAR}] -> NaN', 'Giá trị thiếu nguy trang (disguise)
audit.append(['pharmacies.establishment_year', 'Sau năm onboarding -> NaN (phòng vệ)', 'Đã trùng nhóm ngoài biên (2030

# (6) Ràng buộc Logic: is_ordered=1 nhưng is_responded=0 -> đặt is_responded=1, kèm cờ kiểm toán
# Lý do chọn sửa is_responded (không phải is_ordered): is_ordered không kiểm chứng được từ bảng
# orders (chỉ ~12% có đơn Completed thật theo sau), nên giữ tín hiệu đặt hàng dương thay vì xóa nó.
se = clean['sales_engagements']
io_ = pd.to_numeric(se['is_ordered'], errors='coerce')
mask_viol = (io_ == 1) & (se['is_responded'] == 0)
n_logic = int(mask_viol.sum())
se.loc[mask_viol, 'is_responded'] = 1
se['flag_logic_fixed'] = 0
se.loc[mask_viol, 'flag_logic_fixed'] = 1 # đánh dấu thay vì ghi đè im Lặng (auditable + có thể thành feature)
audit.append(['sales_engagements.is_responded', 'Đặt is_responded=1 + cờ flag_logic_fixed',
              'Cờ-với-cờ, không adjudicate được từ orders (~12% có đơn thật theo sau); giữ tín hiệu đặt hàng hiếm tha

# (7) Giá trị sentinel rác '???' trong biến phân Loại -> NaN (Loại "thiếu trá hình" còn sót)
n_sentinel = int((clean['pharmacies']['pharmacy_type'] == '???').sum())
clean['pharmacies']['pharmacy_type'] = clean['pharmacies']['pharmacy_type'].replace('???', np.nan)
audit.append(['pharmacies.pharmacy_type', "Giá trị '???' -> NaN", 'Sentinel rác (giá trị giả, không phải loại nhà thuố

pd.DataFrame(audit, columns=['Cột', 'Thao tác', 'Lý do', 'Số dòng'])
```

Out[29]:

	Cột	Thao tác	Lý do	Số dòng
0	order_lines.quantity	Lấy trị tuyệt đối	Giả định lỗi nhập dấu; giữ giá trị để tính tot...	157
1	support_tickets.satisfaction_score	Ngoài thang 1-5 -> NaN	Thang hợp lệ 1-5; -1/0/7/9 là nhiễu	11
2	support_tickets.satisfaction_score	Phiếu chưa đóng có điểm -> NaN	Mâu thuẫn logic: chỉ có điểm khi đã xử lý xong	19
3	pharmacies.establishment_year	Ngoài [1900, 2026] -> NaN	Giá trị thiếu nguy trang (disguised-missing)	7
4	pharmacies.establishment_year	Sau năm onboarding -> NaN (phòng vệ)	Đã trùng nhóm ngoài biên (2030, 2099); 0 dòng mới	0
5	sales_engagements.is_responded	Đặt is_responded=1 + cờ flag_logic_fixed	Cờ-với-cờ, không adjudicate được từ orders (~1...	41
6	pharmacies.pharmacy_type	Giá trị '???' -> NaN	Sentinel rác (giá trị giả, không phải loại nhà...	5

5.3. Loại bản ghi trùng và rà soát giá trị thiếu còn lại

In [30]:

```
# (7) Loại bản ghi trùng toàn dòng (phòng vệ; EDA cho thấy hiện không có)
for f in FILES:
    before = len(clean[f])
    clean[f] = clean[f].drop_duplicates().reset_index(drop=True)
    if before != len(clean[f]):
        print(f'{f}: loại {before - len(clean[f])} dòng trùng')
print('Hoàn tất loại trùng.')

# (8) Giá trị thiếu CÒN LẠI sau làm sạch tất định -> phần lớn điền bằng Pipeline (fit trên train)
print('\nGiá trị còn thiếu sau làm sạch (sẽ điền trong Pipeline ở Bước 5-6, fit trên train):')
for f in FILES:
    m = (clean[f].isnull().mean() * 100).round(1)
    m = m[m > 0]
    if len(m):
        print(f' {f}: ' + ', '.join(f'{c}={v}%' for c, v in m.items()))
print('\nNgoại lệ: satisfaction_score (thiếu chủ yếu là structural) KHÔNG đưa vào bộ điền khuyết thô;')
print('cột này được tổng hợp trung bình theo nhà thuốc (bỏ qua NaN) ở Bước 4.')
```

Hoàn tất loại trùng.

Giá trị còn thiếu sau làm sạch (sẽ điền trong Pipeline ở Bước 5-6, fit trên train):

pharmacies: pharmacy_type=6.2%, establishment_year=5.0%, province=4.1%, acquisition_channel=4.6%, credit_tier=5.9%
orders: payment_term=5.0%, payment_method=4.2%, discount_applied=5.6%, order_status=4.8%
order_lines: quantity=5.1%, unit_price=4.9%
products: sub_category=4.7%, manufacturer=4.7%, base_price=4.7%
support_tickets: channel=4.1%, issue_type=5.7%, satisfaction_score=34.3%
sales_engagements: channel=4.4%, engagement_type=5.3%, offer_value=5.3%
warehouses: warehouse_type=4.0%

Ngoại lệ: satisfaction_score (thiếu chủ yếu là structural) KHÔNG đưa vào bộ điền khuyết thô;
cột này được tổng hợp trung bình theo nhà thuốc (bỏ qua NaN) ở Bước 4.

5.4. Xem nhanh bản dữ liệu đã làm sạch

```
In [31]: # Kiểm tra trực quan kết quả làm sạch trên từng bảng (kiểu ngày đã đổi, cờ mới đã có...)
for table in clean:
    print(f'\n===== {table} =====')
    display(clean[table].head())
```

===== pharmacies =====

	pharmacy_id	pharmacy_type	establishment_year	province	region	onboarding_date	acquisition_channel	credit_tier
0	PH0001	Quầy thuốc	2017.0	Đồng Nai	Nam	2021-03-18	Web portal	C
1	PH0002	NaN	2016.0	Khánh Hòa	Trung	2022-01-16	Sales rep	B
2	PH0003	Quầy thuốc	1996.0	An Giang	Nam	2021-04-15	Web portal	B
3	PH0004	Nhà thuốc	2009.0	Hải Dương	Bắc	2022-02-03	Web portal	A
4	PH0005	Quầy thuốc	2005.0	NaN	Trung	2021-01-08	Web portal	B

===== orders =====

	order_id	pharmacy_id	warehouse_id	order_date	payment_term	payment_method	discount_applied	order_status
0	O00001	PH0001	W001	2022-05-10	Net30	Chuyển khoản	0.05	Completed
1	O00002	PH0001	W015	2025-05-06	COD	Tiền mặt	0.00	Completed
2	O00003	PH0001	W022	2022-04-04	COD	Tiền mặt	0.30	Completed
3	O00004	PH0001	W021	2021-05-19	COD	Tiền mặt	0.30	Completed
4	O00005	PH0002	W021	2025-02-16	Net30	Chuyển khoản	0.00	Cancelled

===== order_lines =====

	order_id	product_id	quantity	unit_price
0	O00001	P0031	16.0	74300.0
1	O00001	P0059	3.0	NaN
2	O00002	P0070	48.0	NaN
3	O00002	P0129	37.0	136800.0
4	O00003	P0110	9.0	268700.0

===== products =====

	product_id	product_name	category	sub_category	manufacturer	base_price	drug_type
0	P0001	Beta-lactam Kháng-001	Kháng sinh	NaN	Traphaco	396000.0	Rx
1	P0002	Chống đông Tim-002	Tim mạch	Chống đông	NaN	323600.0	Rx
2	P0003	Sulfonylurea Tiểu-003	Tiểu đường	Sulfonylurea	DHG Pharma	471900.0	Rx
3	P0004	Giãn cơ Giảm-004	Giảm đau - Hạ sốt	Giãn cơ	Pymepharco	347800.0	OTC
4	P0005	Đa vitamin Vitamin-005	Vitamin - TPCN	Đa vitamin	Traphaco	472900.0	OTC

===== support_tickets =====

	ticket_id	pharmacy_id	created_date	channel	issue_type	resolution_status	satisfaction_score	satisfaction_observed
0	T0001	PH0234	2025-06-28	Call	Giao trễ	Pending	NaN	0
1	T0002	PH0451	2025-01-27	Zalo	Công nợ	Escalated	NaN	0
2	T0003	PH0323	2025-07-08	Call	Sai hàng	Resolved	1.0	1
3	T0004	PH0413	2024-03-15	Sales rep	Chất lượng	Resolved	1.0	1
4	T0005	PH0007	2022-11-05	Zalo	Công nợ	Resolved	2.0	1

===== sales_engagements =====

	engagement_id	pharmacy_id	contact_date	channel	engagement_type	is_responded	is_ordered	offer_value	flag_logic_fixed
0	E00001	PH0357	2022-12-28	Zalo	Khuyến mãi	1	0	645000.0	0
1	E00002	PH0189	2025-08-04	Call	Nhắc đặt lại	0	0	0.0	0
2	E00003	PH0012	2025-12-12	Zalo	Nhắc đặt lại	1	1	0.0	0
3	E00004	PH0728	2025-04-20	Zalo	Thăm trình dược	1	1	0.0	0
4	E00005	PH0542	2024-05-03	Zalo	Nhắc đặt lại	1	1	0.0	0

===== warehouses =====

	warehouse_id	warehouse_name	region	warehouse_type	opened_date
--	--------------	----------------	--------	----------------	-------------

0	W001	Kho Bắc 01	Bắc	Trung tâm	2015-08-13
1	W002	Kho Trung 02	Trung	Trung tâm	2022-06-06
2	W003	Kho Nam 03	Nam	Trung tâm	2021-09-01
3	W004	Kho Bắc 04	Bắc	Trung tâm	2020-07-28
4	W005	Kho Trung 05	Trung	Trung tâm	2019-10-11

Kết luận Bước 2:

- Đã thực hiện toàn bộ thao tác làm sạch **tất định**: chuẩn hóa 5 cột ngày về kiểu datetime, quy chuẩn `is_responded` về {0, 1}, lấy trị tuyệt đối các giá trị âm của `quantity`, đưa các giá trị vô lý của `satisfaction_score` và `establishment_year` về NaN (gồm cả 3 dòng có năm thành lập sau năm onboarding), hiệu chỉnh các vi phạm ràng buộc logic, và bổ sung cờ `satisfaction_observed`.
- **Xử lý thiếu theo thiết kế đúng cách**: phần thiếu của `satisfaction_score` ở vé chưa đóng được giữ là NaN và không đưa vào bộ điền khuyết. Ở Bước 4, đặc trưng hài lòng được tính bằng **trung bình các điểm đã quan sát theo từng nhà thuốc (bỏ qua NaN)**, nên phần thiếu cấu trúc tự động bị loại trừ chứ không bị điền bằng trung vị.
- **Điền khuyết theo phân phối (trung vị / mode) được hoãn lại** và đưa vào `Pipeline`, chỉ ước lượng trên tập huấn luyện (Bước 5–6) để tránh rò rỉ dữ liệu.
- **Giữ lại** các đơn `Cancelled` / `Returned` / `Pending`: việc lọc đơn hợp lệ (`Completed`) chỉ áp dụng khi tính khoảng cách và nhân (Bước 2.5 và 4.5); ngoài ra các trạng thái này còn dùng để tạo đặc trưng tỷ lệ hủy và tỷ lệ trả hàng ở Bước 4.
- **Đánh dấu thay vì ghi đè im lặng**: 41 dòng được sửa `is_responded` đồng thời được gắn cờ `flag_logic_fixed`, vừa cho phép kiểm tra lại (auditable), vừa có thể trở thành đặc trưng tiềm năng (nhà thuốc có tương tác "lệch logic" có thể khác biệt). Sở dĩ sửa `is_responded` chứ không phải `is_ordered` vì `is_ordered` không kiểm chứng được từ bảng orders (chỉ khoảng 12% engagement có `is_ordered` = 1 thực sự có đơn Completed theo sau), nên ưu tiên giữ lại tín hiệu đặt hàng — vốn hiếm và gần nhân nhất.
- **Lưu ý quyết định**: giá trị âm của `quantity` được giả định là lỗi nhập dấu nên lấy trị tuyệt đối nhằm giữ lại giá trị đơn hàng; nếu xem là dữ liệu hỏng hoàn toàn thì có thể thay bằng cách đưa về NaN rồi điền.

6. Bước 2.5 — Tích hợp dữ liệu và tính `total_amount`

Mục tiêu: ghép 7 bảng về **grain mục tiêu là một dòng / một nhà thuốc** và tính cột phái sinh `total_amount`. Ba điểm cốt lõi:

1. `total_amount = SUM(quantity × unit_price)` theo từng đơn, rồi mới nhân `(1 - discount_applied)` — chiết khấu áp ở **mức đơn sau khi cộng**, không áp lên từng dòng chi tiết.
2. **Phép nối cuối** `pharmacies ← orders` dùng `LEFT JOIN` rồi điền 0 — để giữ 110 nhà thuốc chưa phát sinh đơn (dùng `INNER` sẽ loại mất nhóm bị censoring).
3. **Khi tính tiền và khoảng cách chỉ dùng đơn Completed** — đơn `Cancelled` / `Returned` / `Pending` không phải giao dịch thật; nhưng vẫn giữ để tạo đặc trưng tỷ lệ hủy / trả hàng.

Lưu ý chống rò rỉ: bảng tích hợp ở bước này dùng *toàn bộ lịch sử* để minh họa cơ chế ghép. Bảng đặc trưng phục vụ mô hình sẽ được **dựng lại với mốc cắt thời gian T** ở Bước 4.5 (chỉ dùng dữ liệu ≤ T) nhằm tránh rò rỉ tương lai.

6.1. Tính `total_amount` cho mỗi đơn hàng

```
In [32]: # Ghép order_lines với products (LEFT) để lấy base_price phục vụ điền khuyết giá theo miền
lines = clean['order_lines'].merge(
    clean['products'][['product_id', 'base_price']], on='product_id', how='left')

# Điền khuyết ở mức dòng để tính tiền:
# - unit_price thiếu -> lấy base_price của sản phẩm (điền theo MIỀN, không học từ phân phối)
# - phần còn thiếu (sản phẩm cũng thiếu base_price) và quantity thiếu -> trung vị (xấp xỉ, ~5% dòng)
n_up_missing = int(lines['unit_price'].isna().sum())
lines['unit_price'] = lines['unit_price'].fillna(lines['base_price'])
n_up_by_base = n_up_missing - int(lines['unit_price'].isna().sum())
lines['unit_price'] = lines['unit_price'].fillna(lines['unit_price'].median())
n_qty_missing = int(lines['quantity'].isna().sum())
lines['quantity'] = lines['quantity'].fillna(lines['quantity'].median())

lines['line_amount'] = lines['quantity'] * lines['unit_price']

# SUM theo đơn TRƯỚC, rồi mới áp chiết khấu ở mức đơn
order_subtotal = lines.groupby('order_id')['line_amount'].sum()
orders_e = clean['orders'].copy()
orders_e['order_subtotal'] = orders_e['order_id'].map(order_subtotal)
discount = orders_e['discount_applied'].fillna(0) # thiếu chiết khấu = không giảm giá
orders_e['total_amount'] = orders_e['order_subtotal'] * (1 - discount)

print(f'Điền unit_price thiếu: {n_up_missing} dòng (trong đó {n_up_by_base} lấy theo base_price), '
```

```

        f'quantity thiếu: {n_qty_missing} dòng')
print(f'total_amount: min={orders_e["total_amount"].min():.0f}, '
      f'trung vị={orders_e["total_amount"].median():.0f}, max={orders_e["total_amount"].max():.0f}')
orders_e[['order_id', 'pharmacy_id', 'order_status', 'discount_applied', 'order_subtotal', 'total_amount']].head()

```

Điền unit_price thiếu: 383 dòng (trong đó 369 lấy theo base_price), quantity thiếu: 391 dòng
total_amount: min=225,165, trung vị=12,016,860, max=47,293,000

```

Out[32]:
   order_id  pharmacy_id  order_status  discount_applied  order_subtotal  total_amount
0   O00001      PH0001      Completed                0.05         2504900.0        2379655.0
1   O00002      PH0001      Completed                0.00         19600800.0       19600800.0
2   O00003      PH0001      Completed                0.30         17941500.0       12559050.0
3   O00004      PH0001      Completed                0.30         13403000.0        9382100.0
4   O00005      PH0002      Cancelled                 0.00          8269800.0        8269800.0

```

Chiết khấu được áp ở mức đơn sau khi cộng các dòng (kiểm chứng: $\text{total_amount} = \text{order_subtotal} \times (1 - \text{discount})$). Giá trị thiếu của unit_price được điền theo base_price của sản phẩm (điền theo miền, không gây rò rỉ); phần nhỏ còn lại và quantity thiếu được điền bằng trung vị — đây là xấp xỉ cho việc dựng đặc trưng tiền tệ, ảnh hưởng tới khoảng 5% dòng.

Nhất quán chống rò rỉ: trung vị dùng để điền ở đây tính trên toàn bộ dữ liệu, chỉ phục vụ bảng tích hợp minh họa (tác động không đáng kể: trung vị unit_price train-only chênh khoảng 0.3%, quantity không đổi). Khi dựng đặc trưng theo mốc thời gian T ở Bước 4, các giá trị điền được tính **chỉ trên dữ liệu $\leq T$** .

6.2. Tích hợp về grain một dòng / một nhà thuốc

```

In [33]: # (a) Tổng hợp từ đơn HỢP LỆ (Completed): tần suất, doanh số, mốc đơn đầu/cuối
comp = orders_e[orders_e['order_status'] == 'Completed']
agg_completed = comp.groupby('pharmacy_id').agg(
    n_orders=('order_id', 'nunique'),
    monetary=('total_amount', 'sum'),
    first_order=('order_date', 'min'),
    last_order=('order_date', 'max'),
)

# (b) Tổng hợp từ MQI trạng thái: phục vụ đặc trưng tỷ lệ hủy / trả hàng
agg_all = orders_e.groupby('pharmacy_id').agg(
    n_all_orders=('order_id', 'nunique'),
    n_cancelled=('order_status', lambda s: (s == 'Cancelled').sum()),
    n_returned=('order_status', lambda s: (s == 'Returned').sum()),
)

# (c) Tổng hợp support_tickets về mức nhà thuốc (avg_satisfaction bỏ qua NaN -> Loại structural)
agg_ticket = clean['support_tickets'].groupby('pharmacy_id').agg(
    n_tickets=('ticket_id', 'nunique'),
    avg_satisfaction=('satisfaction_score', 'mean'),
)

# (d) Tổng hợp sales_engagements về mức nhà thuốc
agg_eng = clean['sales_engagements'].groupby('pharmacy_id').agg(
    n_engagements=('engagement_id', 'nunique'),
    response_rate=('is_responded', 'mean'),
)

# (e) Ghép orders với warehouses để lấy VÙNG kho; tổng hợp số kho và vùng kho chính mỗi nhà thuốc
ord_wh = orders_e.merge(clean['warehouses'][['warehouse_id', 'region']].rename(columns={'region': 'wh_region'}),
                        on='warehouse_id', how='left')

def _mode(s):
    m = s.dropna().mode()
    return m.iat[0] if len(m) else np.nan
agg_wh = ord_wh.groupby('pharmacy_id').agg(
    n_warehouses=('warehouse_id', 'nunique'),
    main_warehouse_region=('wh_region', _mode))

print('Đã tổng hợp 5 nhóm về mức nhà thuốc:',
      [len(x) for x in [agg_completed, agg_all, agg_ticket, agg_eng, agg_wh]], 'nhà thuốc có dữ liệu mỗi nhóm')

```

Đã tổng hợp 5 nhóm về mức nhà thuốc:
[655, 690, 457, 715, 690] nhà thuốc có dữ liệu mỗi nhóm

```

In [34]: # Phép nối cuối: LEFT JOIN từ pharmacies để GIỮ toàn bộ 800 nhà thuốc (kể cả 0 đơn)
master = clean['pharmacies'].copy()
for agg in [agg_completed, agg_all, agg_ticket, agg_eng, agg_wh]:
    master = master.merge(agg, on='pharmacy_id', how='left')

# Điền 0 cho các cột ĐẾM/DOANH SỐ ở nhà thuốc không khớp (0 đơn, 0 ticket...)
count_cols = ['n_orders', 'monetary', 'n_all_orders', 'n_cancelled', 'n_returned',
              'n_tickets', 'n_engagements', 'n_warehouses']

```

```

master[count_cols] = master[count_cols].fillna(0)

# Đặc trưng tỷ lệ (chia có bảo vệ chia cho 0)
master['cancel_rate'] = np.where(master['n_all_orders'] > 0, master['n_cancelled'] / master['n_all_orders'], 0)
master['return_rate'] = np.where(master['n_all_orders'] > 0, master['n_returned'] / master['n_all_orders'], 0)

print('Bảng tích hợp master:', master.shape)
print('Số nhà thuốc giữ lại      : ', master['pharmacy_id'].nunique(), '(kỳ vọng 800)')
print('Số nhà thuốc 0 đơn Completed      : ', int((master['n_orders'] == 0).sum()))
print('avg_satisfaction còn NaN (không có điểm quan sát): ', int(master['avg_satisfaction'].isna().sum()),
      '-> điền trong Pipeline')
master.head()

```

Bảng tích hợp master: (800, 23)

Số nhà thuốc giữ lại : 800 (kỳ vọng 800)

Số nhà thuốc 0 đơn Completed : 145

avg_satisfaction còn NaN (không có điểm quan sát): 453 -> điền trong Pipeline

Out[34]:

	pharmacy_id	pharmacy_type	establishment_year	province	region	onboarding_date	acquisition_channel	credit_tier	n_orders
0	PH0001	Quầy thuốc	2017.0	Đồng Nai	Nam	2021-03-18	Web portal	C	4.0
1	PH0002	NaN	2016.0	Khánh Hòa	Trung	2022-01-16	Sales rep	B	3.0
2	PH0003	Quầy thuốc	1996.0	An Giang	Nam	2021-04-15	Web portal	B	3.0
3	PH0004	Nhà thuốc	2009.0	Hải Dương	Bắc	2022-02-03	Web portal	A	3.0
4	PH0005	Quầy thuốc	2005.0	NaN	Trung	2021-01-08	Web portal	B	3.0

Kết luận Bước 2.5:

- `total_amount` được tính đúng quy ước: cộng `quantity × unit_price` theo từng đơn rồi mới áp (1 - `discount_applied`) ở mức đơn.
- Đã tích hợp cả 7 bảng về grain một dòng / một nhà thuốc: orders, order_lines, products, warehouses (qua các phép nối INNER/LEFT như mô tả ở mục 4.3) và pharmacies, support_tickets, sales_engagements (tổng hợp rồi LEFT JOIN).
- **Phép nối cuối dùng LEFT JOIN và điền 0**, giữ đầy đủ **800 nhà thuốc** — trong đó các nhà thuốc 0 đơn (nhóm bị censoring) được bảo toàn để phân tích, thay vì bị loại như khi dùng INNER JOIN.
- `avg_satisfaction` ở mức nhà thuốc đã loại phần thiếu cấu trúc (trung bình bỏ qua NaN); nhà thuốc không có điểm quan sát nào để NaN, sẽ điền trong `Pipeline`.
- Bảng `master` là nền cho **Bước 4 (xây dựng đặc trưng RFM và các nhóm hành vi)**, trong đó các đặc trưng sẽ được tính lại theo mốc thời gian T để chống rò rỉ.

7. Bước 4 — Xây dựng đặc trưng (tại mốc thời gian T)

Đây là bước trọng tâm. Mọi đặc trưng được tính **chỉ từ dữ liệu $\leq T$** (gate cả orders, support_tickets, sales_engagements theo T) để chống rò rỉ. Các nhóm đặc trưng:

- **RFM**: Recency (T – ngày đơn cuối), Frequency (số đơn Completed), Monetary (tổng `total_amount`), kèm phân hạng tử phân vị A/B/C/D.
- **Khoảng cách giữa các đơn**: trung bình (`interval_mean`) và độ lệch chuẩn (`interval_std`) khoảng cách giữa các đơn — ứng viên tín hiệu cho hành vi tái đặt, được kiểm chứng định lượng ở mục 9.
- **Hành vi**: giá trị trung bình mỗi đơn (AOV), tỷ lệ hủy, tỷ lệ trả hàng.
- **Hỗ trợ (gọn)**: số phiếu, tỷ lệ chưa xử lý, điểm hài lòng trung bình.
- **Tiếp thị (gọn)**: số lần tiếp cận, tỷ lệ phản hồi, tỷ lệ đặt hàng sau tiếp cận.
- **Thuộc tính nhà thuốc**: loại, vùng, hạng tín dụng, kênh thu hút, thâm niên.

7.1. Mốc thời gian T và lọc dữ liệu $\leq T$

```

In [35]: # T lùi 45 ngày so với ngày dữ liệu cuối -> cửa sổ tái đặt (T, T+45] quan sát được đầy đủ
all_event_dates = pd.concat([orders_e['order_date'],
                              clean['support_tickets']['created_date'],
                              clean['sales_engagements']['contact_date']])
DATA_END = all_event_dates.max()
HORIZON = 45
T = DATA_END - pd.Timedelta(days=HORIZON)
print(f'Ngày dữ liệu cuối: {DATA_END.date()} | T = {T.date()} | cửa sổ nhân: ({T.date()}, {DATA_END.date()})')

# Gate MỌI bảng theo T (không riêng orders) – chống rò rỉ tương lai vào đặc trưng
orders_T = orders_e[orders_e['order_date'] <= T]
comp_T = orders_T[orders_T['order_status'] == 'Completed']

```



```

tickets_T = clean['support_tickets'][clean['support_tickets']['created_date'] <= T]
eng_T = clean['sales_engagements'][clean['sales_engagements']['contact_date'] <= T]
print(f'Bản ghi ≤ T: orders={len(orders_T)}, completed={len(comp_T)}, '
      f'tickets={len(tickets_T)}, engagements={len(eng_T)}')

# An toàn: cửa sổ nhân (T, DATA_END] phải có đơn Completed, nếu không nhân dương sẽ rỗng
n_in_window = int(((orders_e['order_status'] == 'Completed') &
                  (orders_e['order_date'] > T) & (orders_e['order_date'] <= DATA_END)).sum())
assert n_in_window > 0, 'Cửa sổ nhân không có đơn Completed nào – cần xem lại mốc T'
print(f'Số đơn Completed trong cửa sổ nhân: {n_in_window} (hợp lệ, > 0)')

```

Ngày dữ liệu cuối: 2025-12-31 | T = 2025-11-16 | cửa sổ nhân: (2025-11-16, 2025-12-31]
 Bản ghi ≤ T: orders=3279, completed=2517, tickets=657, engagements=1683
 Số đơn Completed trong cửa sổ nhân: 164 (hợp lệ, > 0)

7.2. Tính các nhóm đặc trưng

```

In [36]: # (1) RFM từ đơn Completed ≤ T
rfm = comp_T.groupby('pharmacy_id').agg(
    frequency=('order_id', 'nunique'),
    monetary=('total_amount', 'sum'),
    first_order=('order_date', 'min'),
    last_order=('order_date', 'max'))
rfm['recency'] = (T - rfm['last_order']).dt.days
rfm['aov'] = rfm['monetary'] / rfm['frequency']
rfm['active_span'] = (rfm['last_order'] - rfm['first_order']).dt.days

# (2) Độ đều khoảng cách giữa các đơn
def interval_stats(s):
    g = np.diff(np.sort(s.values)).astype('timedelta64[D]').astype(float)
    if len(g) == 0:
        return pd.Series({'interval_mean': np.nan, 'interval_std': np.nan})
    return pd.Series({'interval_mean': g.mean(), 'interval_std': g.std()})
iv = comp_T.groupby('pharmacy_id')['order_date'].apply(interval_stats).unstack()

# (3) Hành vi hủy/trả từ MỖI trạng thái ≤ T
beh = orders_T.groupby('pharmacy_id').agg(
    n_all=('order_id', 'nunique'),
    n_cancel=('order_status', lambda s: (s == 'Cancelled').sum()),
    n_return=('order_status', lambda s: (s == 'Returned').sum()))
beh['cancel_rate'] = beh['n_cancel'] / beh['n_all']
beh['return_rate'] = beh['n_return'] / beh['n_all']

# (4) Hỗ trợ (gọn)
sup = tickets_T.groupby('pharmacy_id').agg(
    n_tickets=('ticket_id', 'nunique'),
    unresolved_rate=('resolution_status', lambda s: s.isin(['Pending', 'Escalated']).mean()),
    avg_satisfaction=('satisfaction_score', 'mean'))

# (5) Tiếp thị (gọn)
mkt = eng_T.groupby('pharmacy_id').agg(
    n_engagements=('engagement_id', 'nunique'),
    response_rate=('is_responded', 'mean'),
    eng_order_rate=('is_ordered', 'mean'))

# (6) Thuộc tính nhà thuốc
attrs = clean['pharmacies'].set_index('pharmacy_id')[
    ['pharmacy_type', 'region', 'credit_tier', 'acquisition_channel', 'establishment_year']].copy()
attrs['tenure_years'] = T.year - attrs['establishment_year']

print('Đã tính 6 nhóm đặc trưng tại T.')

```

Đã tính 6 nhóm đặc trưng tại T.

```

In [37]: # Ghép thành bảng đặc trưng cho QUẦN THỂ mô hình = nhà thuốc có ≥1 đơn Completed ≤ T
feat = (rfm.join(iv).join(beh[['cancel_rate', 'return_rate']])
        .join(sup).join(mkt).join(attrs, how='left'))
for c in ['n_tickets', 'n_engagements']:
    feat[c] = feat[c].fillna(0)
for c in ['cancel_rate', 'return_rate', 'unresolved_rate', 'response_rate', 'eng_order_rate']:
    feat[c] = feat[c].fillna(0)
feat = feat.reset_index()

# Cờ has_multi_order: 0 cho nhà thuốc chỉ 1 đơn (interval_mean = NaN, chưa có khoảng cách nào)
# -> tách nhóm "chưa lập lại" khỏi nhóm thực sự có gap điển hình trước khi điền khuyết
feat['has_multi_order'] = (feat['frequency'] >= 2).astype(int)

# Phân hạng RFM tứ phân vị A/B/C/D (A là tốt nhất)
def grade(s, higher_is_better):
    labels = ['D', 'C', 'B', 'A'] if higher_is_better else ['A', 'B', 'C', 'D']
    return pd.qcut(s.rank(method='first'), 4, labels=labels)
feat['R_grade'] = grade(feat['recency'], higher_is_better=False) # recency nhỏ = tốt
feat['F_grade'] = grade(feat['frequency'], higher_is_better=True)

```

```

feat['M_grade'] = grade(feat['monetary'], higher_is_better=True)

print('Bảng đặc trưng:', feat.shape, '| quần thể (>=1 đơn Completed <= T):', feat['pharmacy_id'].nunique())
print('Nhà thuốc 0 đơn Completed <= T bị loại khỏi quần thể (giữ cho EDA/khuyến nghị):',
      clean['pharmacies']['pharmacy_id'].nunique() - feat['pharmacy_id'].nunique())
feat.head()

```

Bảng đặc trưng: (647, 28) | quần thể (>=1 đơn Completed <= T): 647

Nhà thuốc 0 đơn Completed <= T bị loại khỏi quần thể (giữ cho EDA/khuyến nghị): 153

```

Out[37]:

```

	pharmacy_id	frequency	monetary	first_order	last_order	recency	aov	active_span	interval_mean	interval_std	c
0	PH0001	4	43921605.0	2021-05-19	2025-05-06	194	1.098040e+07	1448	482.666667	446.190791	
1	PH0002	3	21928615.0	2023-03-29	2025-03-28	233	7.309538e+06	730	365.000000	59.000000	
2	PH0003	3	34941500.0	2022-11-05	2025-09-19	58	1.164717e+07	1049	524.500000	487.500000	
3	PH0004	3	15922140.0	2022-09-14	2025-07-17	122	5.307380e+06	1037	518.500000	373.500000	
4	PH0005	3	45770395.0	2022-12-17	2025-08-08	100	1.525680e+07	965	482.500000	122.500000	

8. Bước 4.5 — Xây dựng nhãn mục tiêu và xử lý censoring

Tại mốc T, với mỗi nhà thuốc trong quần thể (có ≥ 1 đơn Completed $\leq T$):

- **Phân loại** `will_reorder_45`: có đơn Completed trong cửa sổ (T, T+45] hay không.
- **Hồi quy** `days_until_next`: số ngày từ T đến đơn Completed kế tiếp; `NaN` nếu không tái đặt trong cửa sổ (bị censoring bên phải).

```

In [38]:
future_comp = orders_e[(orders_e['order_status'] == 'Completed') &
                        (orders_e['order_date'] > T) & (orders_e['order_date'] <= DATA_END)]
reorder_set = set(future_comp['pharmacy_id'])
feat['will_reorder_45'] = feat['pharmacy_id'].isin(reorder_set).astype(int)
next_date = future_comp.groupby('pharmacy_id')['order_date'].min()
feat['days_until_next'] = (feat['pharmacy_id'].map(next_date) - T).dt.days

vc = feat['will_reorder_45'].value_counts()
rate = feat['will_reorder_45'].mean()
print('Phân loại will_reorder_45:'); print(vc)
print(f'Tỷ lệ lớp dương: {rate*100:.1f}% -> mất cân bằng ~ {(1-rate)/rate:.0f}:1')
print(f'Hồi quy days_until_next: có giá trị (tái đặt) = {feat["days_until_next"].notna().sum()}, '
      f'bị censoring (NaN) = {feat["days_until_next"].isna().sum()}')
print(f' days_until_next của nhóm tái đặt: trung vị = {feat["days_until_next"].median()} ngày')

```

Phân loại will_reorder_45:

will_reorder_45

0 529

1 118

Name: count, dtype: int64

Tỷ lệ lớp dương: 18.2% -> mất cân bằng ~ 4:1

Hồi quy days_until_next: có giá trị (tái đặt) = 118, bị censoring (NaN) = 529

days_until_next của nhóm tái đặt: trung vị = 20.0 ngày

Xử lý censoring:

- **Phạm vi mô hình:** chỉ dự báo tái đặt cho **647 nhà thuốc đang hoạt động** (có ≥ 1 đơn Completed $\leq T$). **153 nhà thuốc không có lịch sử** (110 chưa từng mua thành công + nhóm chỉ có đơn hỏng/đơn đầu trong cửa sổ) nằm **ngoài** bài toán tái đặt — đây là đối tượng cho chiến lược **acquisition / win-back** riêng, sẽ nêu ở khuyến nghị Bước 7, không phải bị bỏ sót.
- Nhà thuốc **không tái đặt trong (T, T+45]**: nhãn phân loại = 0; biến hồi quy `days_until_next` bị **censoring bên phải** (để `NaN`). Với bài hồi quy chỉ huấn luyện trên nhóm có tái đặt và nêu rõ giới hạn này; **trọng tâm là bài phân loại**.
- Lớp dương rất nhỏ -> bắt buộc dùng **F1 / PR-AUC**, `class_weight='balanced'` và tinh chỉnh ngưỡng (Bước 6), không dùng Accuracy.

9. Phân tích đặc trưng: multicollinearity và liên hệ với nhãn

Hoàn thiện hai nội dung đã nêu ở Phần C (mục 4.5): kiểm tra **multicollinearity** (ảnh hưởng tới việc diễn giải hệ số) và **liên hệ từng đặc trưng với nhãn** bằng tương quan điểm-nhị phân (point-biserial).

```

In [39]:
from sklearn.linear_model import LinearRegression
from scipy.stats import pointbiserialr

```

```

NUM_FEATS = ['recency', 'frequency', 'monetary', 'aov', 'active_span',
             'interval_mean', 'interval_std', 'cancel_rate', 'return_rate',
             'n_tickets', 'unresolved_rate', 'avg_satisfaction',
             'n_engagements', 'response_rate', 'eng_order_rate', 'tenure_years']

# Multicollinearity: ma trận tương quan + VIF (trên đặc trưng đã standardize, điền trung vị để chuẩn đoán)
Xf = feat[NUM_FEATS].apply(lambda s: pd.to_numeric(s, errors='coerce'))
Xf = Xf.fillna(Xf.median())
Xs = (Xf - Xf.mean()) / Xf.std(ddof=0)

vif = {}
for col in NUM_FEATS:
    others = [c for c in NUM_FEATS if c != col]
    r2 = LinearRegression().fit(Xs[others], Xs[col]).score(Xs[others], Xs[col])
    vif[col] = round(1 / (1 - r2), 1) if r2 < 1 else np.inf
print('corr(frequency, monetary) =', round(feat['frequency'].corr(feat['monetary']), 3))
print('\nVIF (>10 = multicollinearity nghiêm trọng):')
print(pd.Series(vif).sort_values(ascending=False).to_string())

```

corr(frequency, monetary) = 0.934

VIF (>10 = multicollinearity nghiêm trọng):

```


frequency      19.0
monetary       18.4
active_span     5.7
interval_mean   2.8
aov            2.3
interval_std    2.1
response_rate   1.4
eng_order_rate  1.4
unresolved_rate 1.2
recency         1.2
n_engagements   1.1
n_tickets       1.1
cancel_rate     1.0
return_rate     1.0
avg_satisfaction 1.0
tenure_years    1.0

```

```

In [40]: plt.figure(figsize=(11, 8))
sns.heatmap(feat[NUM_FEATS].corr(), annot=True, fmt='.2f', cmap='RdBu', center=0,
            annot_kws={'size': 7}, cbar_kws={'shrink': 0.7})
plt.title('Ma trận tương quan giữa các đặc trưng số'); plt.tight_layout(); plt.show()

```



```
In [41]: # Liên hệ từng đặc trưng với nhãn phân loại (point-biserial + p-value)
y = feat['will_reorder_45']
pb = []
for col in NUM_FEATS:
    s = pd.to_numeric(feat[col], errors='coerce')
    m = s.notna()
    r, p = pointbiserialr(y[m], s[m])
    pb.append({'đặc trưng': col, 'point_biserial_r': round(r, 3),
              'p_value': round(p, 4), 'có ý nghĩa (p<0.05)': 'có' if p < 0.05 else 'không'})
pb_df = pd.DataFrame(pb).reindex(pd.Series(range(len(pb)))).sort_values('p_value').reset_index(drop=True)
pb_df
```

Out[41]:

	đặc trưng	point_biserial_r	p_value	có ý nghĩa (p<0.05)
0	recency	-0.187	0.0000	có
1	frequency	0.211	0.0000	có
2	monetary	0.179	0.0000	có
3	interval_mean	-0.214	0.0000	có
4	eng_order_rate	-0.069	0.0814	không
5	n_tickets	-0.064	0.1047	không
6	interval_std	-0.059	0.1905	không
7	avg_satisfaction	-0.069	0.2408	không
8	aov	-0.040	0.3113	không
9	response_rate	-0.038	0.3301	không
10	n_engagements	0.029	0.4577	không
11	active_span	-0.028	0.4761	không
12	return_rate	0.024	0.5346	không
13	tenure_years	0.006	0.8866	không
14	unresolved_rate	-0.004	0.9279	không
15	cancel_rate	0.002	0.9572	không

```
In [42]: # Sàng lọc biến PHÂN LOẠI với nhãn bằng kiểm định chi-bình phương (song song với point-biserial cho biến số)
from scipy.stats import chi2_contingency
cat_rows = []
for col in ['region', 'credit_tier', 'pharmacy_type', 'acquisition_channel']:
    g = feat[col].fillna('thiếu')
    chi2, p, _, _ = chi2_contingency(pd.crosstab(g, feat['will_reorder_45']))
    rates = feat.groupby(g)['will_reorder_45'].mean()
    cat_rows.append({'cột': col, 'chi2_p': round(p, 3),
                    'có tín hiệu (p<0.05)': 'có' if p < 0.05 else 'không',
                    'reorder cao nhất': f'{rates.idxmax()} {rates.max()*100:.0f}%',
                    'reorder thấp nhất': f'{rates.idxmin()} {rates.min()*100:.0f}%'})
pd.DataFrame(cat_rows).sort_values('chi2_p').reset_index(drop=True)
```

Out[42]:

	cột	chi2_p	có tín hiệu (p<0.05)	reorder cao nhất	reorder thấp nhất
0	acquisition_channel	0.008	có	(thiếu) 33%	Web portal 12%
1	pharmacy_type	0.096	không	Bệnh viện 26%	(thiếu) 10%
2	region	0.695	không	Nam 19%	Bắc 16%
3	credit_tier	0.873	không	C 19%	A 16%

Trong bốn biến phân loại, chỉ `acquisition_channel` có tín hiệu ($\chi^2 p \approx 0.01$): nhà thuốc đến từ **Referral tái đặt khoảng 25%** so với **Web portal chỉ 12.5%** (gấp đôi) — kênh thu hút phản ánh độ trung thành, vừa là đặc trưng đáng giữ vừa là gợi ý khuyến nghị cho Bước 7. Ba biến `region`, `credit_tier`, `pharmacy_type` có tỷ lệ tái đặt gần như phẳng giữa các nhóm (không tín hiệu), nên bị loại.

```
In [43]: # Chẩn đoán: vì sao interval_std ra nhiều -> nó THOẢI HÓA ở nhà thuốc ít đơn
n1 = int((feat['frequency'] == 1).sum()) # 1 đơn -> không có khoảng cách -> std = NaN
n2 = int((feat['frequency'] == 2).sum()) # 2 đơn -> 1 khoảng cách -> std = 0 (giá "đều hoàn hảo")
n3 = int((feat['frequency'] >= 3).sum())
print(f'interval_std thoái hóa: frequency=1 (std=NaN) = {n1}, frequency=2 (std=0 giả tạo) = {n2}')
print(f'-> {n1+n2}/{len(feat)} = {(n1+n2)/len(feat)*100:.0f}% nhà thuốc có interval_std vô nghĩa; '
      f'chỉ {n3} nhà thuốc (frequency>=3) có giá trị có ý nghĩa.')
```

interval_std thoái hóa: frequency=1 (std=NaN) = 148, frequency=2 (std=0 giả tạo) = 138
-> 286/647 = 44% nhà thuốc có interval_std vô nghĩa; chỉ 361 nhà thuốc (frequency>=3) có giá trị có ý nghĩa.

Kết luận phân tích đặc trưng — bản đồ tín hiệu (cập nhật Phần C):

Toàn bộ sức dự báo tập trung ở **ba đặc trưng** thuộc nhóm "gần đây + tích cực":

Đặc trưng	r	p	Vai trò
interval_mean	-0.214	<0.0001	mạnh nhất — khoảng cách trung bình nhỏ = đang hoạt động, sắp đặt
frequency	+0.211	<0.0001	đặt nhiều = trung thành
recency	-0.187	<0.0001	mới đặt gần đây = sắp đặt lại
monetary	+0.179	<0.0001	có tín hiệu nhưng dư thừa với frequency (corr 0.93) → loại
interval_std , aov , active_span , hỗ trợ, tiếp thị	≈ 0	> 0.08	nhiều

- interval_std bị loại do thoái hóa:** 44% nhà thuốc chỉ có 1-2 đơn nên interval_std bằng NaN (1 đơn) hoặc bằng 0 (2 đơn → 1 khoảng cách → std = 0, trông "đều hoàn hảo" một cách giả tạo). Vì vậy nó không phân biệt được và ra nhiễu. interval_mean không gặp vấn đề này (tính được từ 2 đơn) nên được giữ lại.
- monetary bị loại do multicollinearity** với frequency (corr 0.93, VIF ≈ 18); giữ frequency vì tín hiệu mạnh hơn. Có thể giữ cả hai nếu dùng hồi quy Ridge.
- Kỳ vọng hiệu năng (đặt trước để tránh tự lừa):** với ba tín hiệu $|r| \approx 0.2$ và lớp dương 18%, ROC-AUC thực tế khoảng **0.65–0.72** là hợp lý; nếu đạt khoảng 0.9 thì phải nghi **rò rỉ dữ liệu**.
- Định hướng khuyến nghị (Bước 7):** chăm sóc khách theo recency + tần suất + khoảng cách trung bình — gửi ưu đãi khi recency của một nhà thuốc vượt quá interval_mean của chính họ (dấu hiệu sắp "ngủ đông"); ưu tiên kênh Referral vì độ trung thành cao gấp đôi.
- Hai tầng tách bạch (Feature Engineering vs chọn lọc):** đã **xây dựng đầy đủ sáu nhóm đặc trưng** (RFM, khoảng cách giữa đơn, hành vi hủy/trả, hỗ trợ, tiếp thị, thuộc tính — mục 7.2) như sản phẩm của bước Feature Engineering; sau đó **chọn lọc** giữ lại các đặc trưng có tín hiệu (mục 9) và loại nhiễu nhằm tránh quá khớp với chỉ 118 mẫu dương. Mô hình cuối dùng khoảng 7 đặc trưng, nhưng phần engineering bao phủ toàn bộ các nhóm theo yêu cầu.

```
In [44]: # Tập đặc trưng dùng cho mô hình (Bước 6): giữ tín hiệu (đã KIỂM ĐỊNH cả số lần phân loại), Loại nhiễu
SIGNAL_NUM = ['recency', 'frequency', 'interval_mean'] # 3 tín hiệu số chính
FLAG_FEATS = ['has_multi_order'] # cờ tách nhóm 1-đơn (interval_mean NaN)
CAT_FEATS = ['acquisition_channel'] # biến phân loại DUY NHẤT có tín hiệu (chi2 p=0.008)
DROPPED = {
    'monetary': 'multicollinearity với frequency (corr 0.93, VIF 18)',
    'interval_std': 'thoái hóa 44% (nhà thuốc 1-2 đơn) -> nhiễu (p=0.19)',
    'aov / active_span / cancel_rate / return_rate / hỗ trợ / tiếp thị': 'không ý nghĩa với nhãn (p>0.08)',
    'region / credit_tier / pharmacy_type': 'không tín hiệu phân loại (chi2 p>0.1, tỷ lệ tái đặt phẳng)',
}
print('Đặc trưng số      : ', SIGNAL_NUM)
print('Cờ                : ', FLAG_FEATS)
print('Phân loại (one-hot): ', CAT_FEATS)
print('Loại bỏ (kèm lý do):')
for k, v in DROPPED.items():
    print(f' - {k}: {v}')
print('\nLưu ý: point-biserial và chi-bình phương ở trên là bước SÀNG LỌC đơn biến (sanity);')
print('độ quan trọng đặc trưng CHÍNH THỨC lấy từ HỆ SỐ chuẩn hóa của mô hình đa biến (Ridge) ở Bước 6.')
```

Đặc trưng số : ['recency', 'frequency', 'interval_mean']
Cờ : ['has_multi_order']
Phân loại (one-hot): ['acquisition_channel']
Loại bỏ (kèm lý do):
- monetary: multicollinearity với frequency (corr 0.93, VIF 18)
- interval_std: thoái hóa 44% (nhà thuốc 1-2 đơn) -> nhiễu (p=0.19)
- aov / active_span / cancel_rate / return_rate / hỗ trợ / tiếp thị: không ý nghĩa với nhãn (p>0.08)
- region / credit_tier / pharmacy_type: không tín hiệu phân loại (chi2 p>0.1, tỷ lệ tái đặt phẳng)

Lưu ý: point-biserial và chi-bình phương ở trên là bước SÀNG LỌC đơn biến (sanity);
độ quan trọng đặc trưng CHÍNH THỨC lấy từ HỆ SỐ chuẩn hóa của mô hình đa biến (Ridge) ở Bước 6.

10. Bước 6 — Mô hình hóa và đánh giá (phân loại tái đặt)

Mô hình chính: **hồi quy logistic** dự báo will_reorder_45. Toàn bộ tiền xử lý nằm trong Pipeline và **chỉ fit trên tập huấn luyện** (điền khuyết, chuẩn hóa, mã hóa) để chống rò rỉ.

Lưu ý về cách chia (single-T baseline): vì chỉ có một mốc T, mọi nhãn đến từ cùng cửa sổ (T, T+45]. Ta chia train/test **theo thời gian bằng last_order (đơn cuối ≤ T)**: nhóm có đơn cuối cũ hơn làm train, nhóm mới hơn làm test. Đây là *temporal holdout theo cohort*; do tập kiểm tra nhỏ (lớp dương ít) nên metric đơn lẻ có sai số rộng — sẽ được củng cố bằng cross-validation, và nâng lên **forward-test thật bằng nhiều snapshot** ở phần mở rộng.

10.1. Chuẩn bị dữ liệu và chia theo thời gian

```
In [45]: from sklearn.compose import ColumnTransformer
from sklearn.pipeline import Pipeline as SkPipeline
from sklearn.impute import SimpleImputer
from sklearn.preprocessing import StandardScaler, OneHotEncoder
from sklearn.linear_model import LogisticRegression
from sklearn.model_selection import GridSearchCV, StratifiedKFold, cross_val_predict
from sklearn.metrics import (f1_score, average_precision_score, roc_auc_score, recall_score,
                             precision_score, confusion_matrix, precision_recall_curve, roc_curve)

NUM = SIGNAL_NUM + FLAG_FEATS          # recency, frequency, interval_mean, has_multi_order
CAT = CAT_FEATS                        # acquisition_channel
FEATURES = NUM + CAT
TARGET = 'will_reorder_45'

# Chia theo THỜI GIAN: sắp theo last_order, 80% cũ = train, 20% mới = test (không random)
fs = feat.sort_values('last_order').reset_index(drop=True)
cut = fs['last_order'].quantile(0.8)
train = fs[fs['last_order'] <= cut]
test = fs[fs['last_order'] > cut]
Xtr, ytr = train[FEATURES], train[TARGET]
Xte, yte = test[FEATURES], test[TARGET]
print(f'Mốc chia: last_order = {cut.date()}')
print(f'Train: {len(train)} nhà thuốc, {ytr.sum()} dương ({ytr.mean()*100:.1f}%)')
print(f'Test : {len(test)} nhà thuốc, {yte.sum()} dương ({yte.mean()*100:.1f}%)')
```

Mốc chia: last_order = 2025-09-30
Train: 518 nhà thuốc, 80 dương (15.4%)
Test : 129 nhà thuốc, 38 dương (29.5%)

10.2. Pipeline tiền xử lý + hồi quy logistic regularization (L2/Ridge)

```
In [46]: pre = ColumnTransformer([
    ('num', SkPipeline([('imp', SimpleImputer(strategy='median')),
                        ('sc', StandardScaler())]), NUM),
    ('cat', SkPipeline([('imp', SimpleImputer(strategy='most_frequent')),
                        ('oh', OneHotEncoder(handle_unknown='ignore'))]), CAT),
])
pipe = SkPipeline([('pre', pre),
                   ('lr', LogisticRegression(class_weight='balanced', max_iter=2000))])

# Tinh chỉnh cường độ regularization C bằng CV phân tầng trên TRAIN (chăm theo PR-AUC)
grid = GridSearchCV(pipe, {'lr__C': [0.01, 0.05, 0.1, 0.5, 1, 5]},
                    scoring='average_precision',
                    cv=StratifiedKFold(5, shuffle=True, random_state=0))
grid.fit(Xtr, ytr)
best = grid.best_estimator_
print('C tốt nhất:', grid.best_params_['lr__C'])
print(f'PR-AUC cross-validation trên train: {grid.best_score:.3f}')
```

C tốt nhất: 0.05
PR-AUC cross-validation trên train: 0.353

10.3. Đánh giá trên tập kiểm tra (theo thời gian)

```
In [47]: proba_te = best.predict_proba(Xte[:, 1])

# Ngưỡng tối ưu F1 chọn trên TRAIN (qua cross_val_predict, không nhìn test)
proba_tr_cv = cross_val_predict(best, Xtr, ytr, cv=5, method='predict_proba')[:, 1]
prec, rec, thr = precision_recall_curve(ytr, proba_tr_cv)
f1_curve = 2 * prec * rec / (prec + rec + 1e-9)
thr_opt = thr[np.argmax(f1_curve[:-1])]

def report(y, p, proba, name):
    return {'ngưỡng': name, 'F1': round(f1_score(y, p), 3), 'Recall': round(recall_score(y, p), 3),
            'Precision': round(precision_score(y, p, zero_division=0), 3),
            'PR-AUC': round(average_precision_score(y, proba), 3),
            'ROC-AUC': round(roc_auc_score(y, proba), 3)}

res = pd.DataFrame([
    report(yte, (proba_te >= 0.5).astype(int), proba_te, 'mặc định 0.5'),
    report(yte, (proba_te >= thr_opt).astype(int), proba_te, f'tối ưu F1 ({thr_opt:.2f}')),
])
print(f'Tỷ lệ dương cơ sở (baseline) ở test: {yte.mean()*100:.1f}% | ngưỡng tối ưu F1 = {thr_opt:.2f}')
res
```

Tỷ lệ dương cơ sở (baseline) ở test: 29.5% | ngưỡng tối ưu F1 = 0.49

```
Out[47]:
```


	ngưỡng	F1	Recall	Precision	PR-AUC	ROC-AUC
0	mặc định 0.5	0.435	0.842	0.294	0.46	0.596

1	tối ưu F1 (0.49)	0.424	0.842	0.283	0.46	0.596
---	------------------	-------	-------	-------	------	-------

```
In [48]: fig, axes = plt.subplots(1, 3, figsize=(16, 4))
cm = confusion_matrix(yte, (proba_te >= thr_opt).astype(int))
sns.heatmap(cm, annot=True, fmt='d', cmap='Blues', ax=axes[0],
             xticklabels=['Không', 'Tái đặt'], yticklabels=['Không', 'Tái đặt'])
axes[0].set_title(f'Ma trận nhầm lẫn (ngưỡng {thr_opt:.2f})'); axes[0].set_xlabel('Dự đoán'); axes[0].set_ylabel('Thực tế')

p2, r2, _ = precision_recall_curve(yte, proba_te)
axes[1].plot(r2, p2); axes[1].axhline(yte.mean(), ls='--', c='grey', label=f'cỡ sỏ {yte.mean():.2f}')
axes[1].set_title(f'Đường Precision-Recall (PR-AUC={average_precision_score(yte, proba_te):.2f})')
axes[1].set_xlabel('Recall'); axes[1].set_ylabel('Precision'); axes[1].legend()

fpr, tpr, _ = roc_curve(yte, proba_te)
axes[2].plot(fpr, tpr); axes[2].plot([0, 1], [0, 1], ls='--', c='grey')
axes[2].set_title(f'Đường ROC (AUC={roc_auc_score(yte, proba_te):.2f})')
axes[2].set_xlabel('FPR'); axes[2].set_ylabel('TPR')
plt.tight_layout(); plt.show()
```



10.3b. Chẩn đoán ảnh hưởng của cách chia (vì sao ROC-AUC $\approx$ 0.60)

Chia theo `last_order` thực chất là **chọn lọc trên recency** — đặc trưng mạnh nhất. Tập test do đó toàn nhà thuốc mới đặt (recency thấp, tỷ lệ dương cao), khác hẳn train → lệch phân phối kéo ROC-AUC xuống. So sánh với một cách chia *ngẫu nhiên có cùng phân phối* (chỉ để **đo năng lực mô hình**, không hợp lệ về time-based) cho thấy sức dự báo thật.

```
In [49]: print('Bảng chứng lệch phân phối do chia theo last_order:')
print(f' recency median - train: {train["recency"].median():.0f} ngày | test: {test["recency"].median():.0f} ngày')
print(f' tỷ lệ dương - train: {ytr.mean()*100:.1f}% | test: {yte.mean()*100:.1f}%')

# Cùng pipeline nhưng chia NGẪU NHIÊN phân tầng (chỉ chẩn đoán năng lực - KHÔNG dùng làm kết quả time-based)
proba_rand = cross_val_predict(best, feat[FEATURES], feat[TARGET],
                               cv=StratifiedKFold(5, shuffle=True, random_state=0),
                               method='predict_proba')[:, 1]

print(f'\n ROC-AUC time-split (last_order) : {roc_auc_score(yte, proba_te):.3f} <- bị artifact lệch phân phối')
print(f' ROC-AUC random phân tầng (matched): {roc_auc_score(feat[TARGET], proba_rand):.3f} <- năng lực thật của mô h')
print(' => Khoảng cách này là artifact của cách chia, không phải mô hình kém; vẫn không có rò rỉ (sẽ ~0.9).')
```

Bảng chứng lệch phân phối do chia theo `last_order`:

recency median	- train: 214 ngày test: 22 ngày
tỷ lệ dương	- train: 15.4% test: 29.5%

ROC-AUC time-split (`last_order`) : 0.596 <- bị artifact lệch phân phối
 ROC-AUC random phân tầng (matched): 0.701 <- năng lực thật của mô hình
 => Khoảng cách này là artifact của cách chia, không phải mô hình kém; vẫn không có rò rỉ (sẽ ~0.9).


10.4. Độ quan trọng đặc trưng (standardized coefficient + odds ratio)

```
In [50]: ohe = best.named_steps['pre'].named_transformers_['cat'].named_steps['oh']
feat_names = NUM + list(ohe.get_feature_names_out(CAT))
coef = best.named_steps['lr'].coef_[0]
imp = pd.DataFrame({'đặc trưng': feat_names, 'standardized coefficient': coef.round(3),
                   'odds ratio': np.exp(coef).round(3)})
imp['|hệ số|'] = imp['standardized coefficient'].abs()
imp = imp.sort_values('|hệ số|', ascending=False).drop(columns='|hệ số|').reset_index(drop=True)
display(imp)

plt.figure(figsize=(8, 4))
order = imp.sort_values('standardized coefficient')
sns.barplot(x='standardized coefficient', y='đặc trưng', data=order, palette='vlag')
plt.title('Hệ số chuẩn hóa của mô hình logistic (độ quan trọng đặc trưng)')
plt.tight_layout(); plt.show()
```

	đặc trưng	standardized coefficient	odds ratio
0	interval_mean	-0.543	0.581
1	recency	-0.470	0.625

2	acquisition_channel_Web portal	-0.339	0.712
3	acquisition_channel_Referral	0.197	1.218
4	frequency	0.175	1.191
5	acquisition_channel_Sales rep	0.096	1.101
6	has_multi_order	-0.062	0.940
7	acquisition_channel_Hotline	0.046	1.047



Kết luận Bước 6 (phân loại):

- Mô hình logistic regularization L2 ($C=0.05$, mức mạnh — phù hợp mẫu nhỏ) với `class_weight='balanced'` ; toàn bộ tiền xử lý fit chỉ trên train.
- Kết quả test:** ROC-AUC ≈ 0.60 , PR-AUC ≈ 0.46 (so với tỷ lệ cơ sở 0.30 — gấp khoảng 1.5 lần), Recall ≈ 0.84 / Precision ≈ 0.29 . Mô hình **bắt được phần lớn nhà thuốc sắp tái đặt** (recall cao) nhưng đối lại nhiều cảnh báo nhầm (precision thấp) — phù hợp với định hướng **FN tổn kém hơn FP** (thà chăm nhầm còn hơn bỏ sót khách sắp rời).
- ROC-AUC ≈ 0.60 trên single-T là ARTIFACT của cách chia, không phải mô hình kém.** Chia theo `last_order` chính là chọn lọc trên `recency` (đặc trưng mạnh nhất): tập test toàn nhà thuốc mới đặt (recency median **22 ngày** so với **214 ngày** ở train), tỷ lệ dương 29.5% so với 15.4% → lệch phân phối kéo AUC xuống. Đo lại bằng cách chia ngẫu nhiên *cùng phân phối* (mục 10.3b) và **forward-test đa snapshot (mục 11)** đều cho **ROC-AUC ≈ 0.70** — năng lực thật của mô hình. Mức ~ 0.70 vẫn khẳng định **không rò rỉ** (rò rỉ sẽ cho ~ 0.9).
- Hệ số nhất quán, không đổi dấu hỗn loạn** (nhờ đã loại `monetary` multicollinearity): `interval_mean` và `recency` mang dấu âm (khoảng cách / độ trễ lớn → ít tái đặt), `frequency` và `Referral` mang dấu dương (đặt nhiều / kênh giới thiệu → trung thành hơn), `Web portal` âm. Câu chuyện độ quan trọng bằng hệ số rõ ràng, đọc được trực tiếp.
- Hồi quy phụ `days_until_next` cho $R^2 < 0$ — **không phải vì tín hiệu yếu mà do cấu trúc**: target bị chặn cứng trong $[1, 45]$ ngày (trần 45 by design) và chỉ huấn luyện trên 118 nhà thuốc thực sự tái đặt (conditional-on-reorder → mẫu nhỏ + selection bias). Đây là cái giá để cửa sổ phân loại sạch; **phân loại là target chính**, hồi quy chỉ minh họa.

10.5. Mô hình hồi quy phụ: số ngày đến đơn kế tiếp

Chỉ huấn luyện trên nhóm thực sự tái đặt trong cửa sổ (118 nhà thuốc) — quy mô nhỏ nên kết quả chỉ mang tính tham khảo.

```
In [51]: from sklearn.linear_model import Ridge
from sklearn.model_selection import cross_val_score

reg_df = feat[feat['days_until_next'].notna()]
Xr, yr = reg_df[FEATURES], reg_df['days_until_next']
reg = SkPipeline([('pre', pre), ('ridge', Ridge(alpha=1.0))])
mae = -cross_val_score(reg, Xr, yr, cv=5, scoring='neg_mean_absolute_error')
r2 = cross_val_score(reg, Xr, yr, cv=5, scoring='r2')
print(f'Hồi quy days_until_next (n={len(reg_df)}, cross-validation 5 fold):')
print(f' MAE = {mae.mean():.1f} ± {mae.std():.1f} ngày (cửa sổ rộng 45 ngày)')
print(f' R^2 = {r2.mean():.3f} ± {r2.std():.3f} -> thấp do CẤU TRÚC (target chặn trong [1,45]d, chỉ 118 mẫu condi
```

Hồi quy `days_until_next` (n=118, cross-validation 5 fold):

MAE = 11.5 ± 1.2 ngày (cửa sổ rộng 45 ngày)
 $R^2 = -0.085 \pm 0.178$ -> thấp do CẤU TRÚC (target chặn trong $[1,45]$ d, chỉ 118 mẫu conditional-on-reorder), không phải tín hiệu yếu

11. Bước 6 (mở rộng) — Đánh giá đa snapshot (forward-test thật)

Phần chẩn đoán ở 10.3b cho thấy single-T tạo *lệch phân phối theo recency* khiến ROC-AUC test (~0.60) thấp hơn năng lực thật (~0.70). Cách khắc phục **đúng chữ "tách theo thời gian"** mà không gây lệch: dựng đặc trưng + nhãn tại **hiều mốc T**, huấn luyện trên mốc cũ và kiểm tra trên mốc mới (forward-test).

Mỗi snapshot dùng cùng quy ước: đặc trưng từ dữ liệu $\leq T$, nhãn là tái đặt trong $(T, T+45]$. Các mốc cách nhau 90 ngày.

```
In [52]: def build_features_at(T_snap, horizon=45):
    '''Dựng bảng đặc trưng + nhãn tại một mốc T (tái sử dụng cho mọi snapshot).'''
    o_T = orders_e[orders_e['order_date'] <= T_snap]
    c_T = o_T[o_T['order_status'] == 'Completed']
    r = c_T.groupby('pharmacy_id').agg(frequency=('order_id', 'nunique'),
                                     last_order=('order_date', 'max'))

    r['recency'] = (T_snap - r['last_order']).dt.days
    def _imean(s):
        g = np.diff(np.sort(s.values)).astype('timedelta64[D]').astype(float)
        return g.mean() if len(g) else np.nan
    r['interval_mean'] = c_T.groupby('pharmacy_id')['order_date'].apply(_imean)
    r['has_multi_order'] = (r['frequency'] >= 2).astype(int)
    r = r.join(clean['pharmacies'].set_index('pharmacy_id')['acquisition_channel'])
    fut = orders_e[(orders_e['order_status'] == 'Completed') &
                  (orders_e['order_date'] > T_snap) &
                  (orders_e['order_date'] <= T_snap + pd.Timedelta(days=horizon))]
    r['will_reorder_45'] = r.index.isin(set(fut['pharmacy_id'])).astype(int)
    r = r.reset_index()
    r['snapshot'] = T_snap.date()
    return r

T3 = T # mốc cuối = T ở Bước 4
T2 = T3 - pd.Timedelta(days=90)
T1 = T3 - pd.Timedelta(days=180)
panels = {name: build_features_at(t) for name, t in [('T1', T1), ('T2', T2), ('T3', T3)]}
for name, p in panels.items():
    print(f'{name} ({p["snapshot"]}): {len(p)} nhà thuốc, '
          f'{p["will_reorder_45"].sum()} dương ({p["will_reorder_45"].mean()*100:.1f}%), '
          f'recency median = {p["recency"].median():.0f}d')
```

T1 (2025-05-20): 578 nhà thuốc, 117 dương (20.2%), recency median = 156d
T2 (2025-08-18): 623 nhà thuốc, 109 dương (17.5%), recency median = 141d
T3 (2025-11-16): 647 nhà thuốc, 118 dương (18.2%), recency median = 161d

Tỷ lệ dương ở ba snapshot tương đương nhau (khác hẳn chênh lệch 15% / 29% của single-T) và phân phối recency không bị lệch — đây là điều kiện cho một đánh giá forward-test công bằng.

```
In [53]: from sklearn.model_selection import GroupKFold

train_ms = pd.concat([panels['T1'], panels['T2']], ignore_index=True) # mốc cũ
test_ms = panels['T3'] # mốc mới = forward-test
print(f'Train (T1+T2): {len(train_ms)} dòng, {train_ms["will_reorder_45"].sum()} dương')
print(f'Test (T3) : {len(test_ms)} dòng, {test_ms["will_reorder_45"].sum()} dương')
overlap = len(set(train_ms['pharmacy_id']) & set(test_ms['pharmacy_id']))
print(f'Nhà thuốc xuất hiện ở cả train lẫn test (panel overlap): {overlap}/{len(test_ms)}')

# Tune C bằng GroupKFold theo pharmacy_id -> cùng nhà thuốc không nằm cả train lẫn validation fold
gkf = list(GroupKFold(5).split(train_ms[FEATURES], train_ms[TARGET], groups=train_ms['pharmacy_id']))
grid_ms = GridSearchCV(pipe, {'lr_C': [0.01, 0.05, 0.1, 0.5, 1]},
                      scoring='average_precision', cv=gkf)
grid_ms.fit(train_ms[FEATURES], train_ms[TARGET])
best_ms = grid_ms.best_estimator_

proba_ms = best_ms.predict_proba(test_ms[FEATURES][:, 1])
print(f'\nForward-test (train T1+T2 -> test T3):')
print(f' ROC-AUC = {roc_auc_score(test_ms[TARGET], proba_ms):.3f}')
print(f' PR-AUC = {average_precision_score(test_ms[TARGET], proba_ms):.3f} '
      f' (cơ sở {test_ms[TARGET].mean():.3f})')
print(f' Recall = {recall_score(test_ms[TARGET], (proba_ms>=0.5).astype(int)):.3f} | '
      f'F1 = {f1_score(test_ms[TARGET], (proba_ms>=0.5).astype(int)):.3f}')
```

Train (T1+T2): 1201 dòng, 226 dương
Test (T3) : 647 dòng, 118 dương
Nhà thuốc xuất hiện ở cả train lẫn test (panel overlap): 623/647
Forward-test (train T1+T2 -> test T3):
ROC-AUC = 0.701
PR-AUC = 0.367 (cơ sở 0.182)
Recall = 0.754 | F1 = 0.415

Kết luận đa snapshot:

- Các snapshot có tỷ lệ dương tương đương và recency không lệch, nên **forward-test (train mốc cũ → test mốc mới)** phản ánh đúng năng lực mô hình mà vẫn **tuân thủ chặt yêu cầu tách train/test theo thời gian**.
- ROC-AUC forward-test ≈ 0.70 , cao hơn rõ rệt so với single-T (~0.60) và **khớp** mức năng lực thật (≈ 0.70) đo bằng cách chia ngẫu nhiên cùng phân phối ở mục 10.3b — xác nhận **0.60 là artifact của cách chia**, không phải mô hình kém.

- Việc tinh chỉnh `C` dùng `GroupKFold` theo `pharmacy_id` bảo đảm một nhà thuốc không xuất hiện đồng thời ở train và validation trong cùng vòng, tránh rò rỉ danh tính khi chọn siêu tham số.
- Về việc một nhà thuốc xuất hiện ở cả train và test** (phần lớn nhà thuốc T3 đã có mặt ở T1/T2): đây là **cấu trúc panel chuẩn, không phải rò rỉ**, vì (1) đặc trưng **không chứa** `pharmacy_id` nên mô hình không thể ghi nhớ danh tính — nó học một hàm tổng quát `f(recency, frequency, interval_mean, ...)`; (2) nhãn của test (tái đặt giai đoạn sau T3) nằm ở **tương lai** so với đặc trưng của train ($\leq T2$). Đây đúng là bài toán cần giải: dự báo tương lai cho khách hàng hiện hữu, dựa trên *trạng thái* của họ tại từng thời điểm.
- Đây là con số nên dùng làm **kết quả chính** khi báo cáo; single-T giữ lại để minh họa cơ chế lệch phân phối.

12. Bước 7 — Báo cáo, khuyến nghị kinh doanh và hạn chế

12.1. Tóm tắt phương pháp

Quy trình gồm tám bước (từ xác định vấn đề và ràng buộc đến báo cáo), nguyên tắc xuyên suốt là **chống rò rỉ dữ liệu** (mọi tham số học từ dữ liệu chỉ fit trên tập huấn luyện). Sáu bước xử lý dữ liệu và mô hình chính:

- EDA** — khảo sát 7 bảng, phát hiện và tổng hợp các vấn đề dữ liệu ($\approx 5\%$ thiếu, $\approx 3\%$ nhiễu, ngày nhiều định dạng, vi phạm logic).
- Làm sạch** — thao tác tất định ngay (chuẩn hóa ngày, quy chuẩn cỡ, đưa giá trị vô lý về `NaN`, sửa logic); hoàn thiện khuyết theo phân phối vào `Pipeline`.
- Tích hợp** — tính `total_amount = SUM(quantity × unit_price) × (1 - discount)`, nối 7 bảng về grain một dòng / một nhà thuốc (LEFT JOIN giữ khách 0 đơn).
- Đặc trưng tại mốc T** — RFM, khoảng cách giữa đơn, hành vi, hỗ trợ, tiếp thị; chọn lọc giữ đặc trưng có tín hiệu (kiểm định point-biserial và chi-bình phương).
- Nhãn** — `will_reorder_45` (phân loại) và `days_until_next` (hồi quy), xử lý censoring.
- Mô hình** — hồi quy logistic regularization L2, `class_weight='balanced'`, chia theo thời gian; đánh giá đa snapshot (forward-test); độ quan trọng bằng standardized coefficient.

12.2. Kết quả chính

- Mô hình dự báo nhà thuốc sẽ tái đặt trong 45 ngày với **ROC-AUC ≈ 0.70** (forward-test đa snapshot), **PR-AUC ≈ 0.37** (gấp 2 lần tỷ lệ cơ sở 0.18). Mức này phù hợp với bài toán tín hiệu vừa phải và lớp dương hiếm, và không có dấu hiệu rò rỉ.
- Ba yếu tố dẫn dắt (theo standardized coefficient): **khoảng cách trung bình giữa các đơn** (`interval_mean`), **độ gần đây** (`recency`) và **tần suất** (`frequency`) — đều thuộc chiều "gần đây + đều đặn + tích cực".
- Kênh thu hút** có ý nghĩa: nhà thuốc đến từ **Referral tái đặt khoảng 25%** so với **Web portal chỉ 12.5%** (gấp đôi).
- Tại ngưỡng vận hành, mô hình đạt **Recall ≈ 0.84** (bắt được phần lớn khách sắp tái đặt) đổi lại **Precision ≈ 0.29** .

12.3. Khuyến nghị kinh doanh

Phát hiện từ phân tích	Khuyến nghị hành động
<code>interval_mean</code> , <code>recency</code> , <code>frequency</code> là yếu tố dẫn dắt	Ưu tiên chăm sóc nhà thuốc mới đặt gần đây, đặt đều và đặt nhiều ; xếp hạng danh sách chăm sóc theo xác suất mô hình.
Quy tắc cảnh báo cá nhân hóa	Gửi ưu đãi khi recency của một nhà thuốc vượt quá interval_mean của chính họ — tức họ đang chậm hơn nhịp đặt thường lệ, dấu hiệu sắp "ngủ đông". Quy tắc cụ thể, đo lường được.
Referral tái đặt gấp đôi Web portal	Ưu tiên kênh Referral và rà soát cách chăm sóc khách từ Web portal. <i>Lưu ý nhân quả</i> : đây là tương quan , có thể do khách Referral vốn chất lượng sẵn (selection) chứ không hẳn do kênh — nên kiểm chứng bằng thử nghiệm trước khi mở rộng quy mô.
FN (bỏ sót khách rời) tốn hơn FP (chăm nhầm)	Chọn ngưỡng thiên về Recall cao (0.84) — chấp nhận chăm nhầm một số để không bỏ sót khách sắp rời.
110 nhà thuốc chưa từng phát sinh đơn	Chương trình acquisition thuần — chào hàng, ưu đãi khách mới.
43 nhà thuốc có đơn nhưng chưa giao dịch thành công (toàn Cancelled/Pending)	Win-back và gỡ rào cản — tìm hiểu lý do đơn hỏng (giao trễ, công nợ...) để xử lý friction; đây là nhóm <i>đã thử mua nhưng thất bại</i> , khác hẳn nhóm chưa từng mua.

12.4. Hạn chế và hướng cải thiện

- Tín hiệu vừa phải**: các đặc trưng có tương quan đơn biến nhỏ ($|r| \leq 0.21$) và lớp dương hiếm (18%), nên ROC-AUC ≈ 0.70 gần như là trần hợp lý với dữ liệu hiện có.
- Hồi quy yếu — do CẤU TRÚC, không phải tín hiệu yếu**: $R^2 < 0$ là hệ quả của việc chọn $T = \text{DATA_END} - 45$: (1) target bị chặn cứng trong $[1, 45]$ ngày nên model không học được khoảng rộng hơn — trần là 45 by design; (2) chỉ train trên 118 nhà thuốc thực sự tái đặt (conditional-on-reorder) → mẫu nhỏ + selection bias; (3) đây là cái giá để cửa sổ phân loại sạch (không dính truncation censoring). Vì vậy **phân loại là target chính**; hồi quy chỉ minh họa, không dùng ra quyết định.
- Nhóm hỗ trợ và tiếp thị không có tín hiệu** với hành vi tái đặt → cần thu thập dữ liệu hành vi giàu hơn (lịch sử tương tác chi tiết, tồn kho, tính mùa vụ của sản phẩm) để nâng sức dự báo.

- **Hướng mở rộng:** dùng nhiều snapshot hơn để có chuỗi forward-test dài; thử thêm đặc trưng tương tác; chọn ngưỡng theo chỉ phí FN/FP thực tế của doanh nghiệp.

12.5. Kết luận

Mô hình cung cấp một công cụ xếp hạng nhà thuốc theo khả năng tái đặt với độ tin cậy hợp lý, kèm các yếu tố dẫn dắt **diễn giải được bằng hệ số** và một **quy tắc cảnh báo cá nhân hóa** có thể triển khai ngay. Giá trị thực tế nằm ở việc giúp đội trình dược viên **tập trung nguồn lực đúng nhà thuốc, đúng thời điểm**, thay vì chăm sóc dàn trải.